

Parte 2 : Classificação

Introdução

Introdução

Regressão vs Classificação

O problema de classificação é um problema similar ao de predição em regressão.

Regressão

Predizer valores numéricos

Exemplos:

- ▶ preço
- ▶ temperatura
- ▶ vendas

$$Y \in \mathbb{R}$$

Classificação

Predizer categorias

Exemplos:

- ▶ spam/não spam
- ▶ fraude/não fraude
- ▶ doente/saudável

$$Y \in \{1, \dots, K\}$$

Formulação do problema

Observamos:

$$(X_1, Y_1), \dots, (X_n, Y_n)$$

onde:

- ▶ $X_i \rightarrow$ variáveis explicativas
- ▶ $Y_i \rightarrow$ classe

Objetivo: construir uma função $g(\mathbf{x})$ capaz de prever a classe de novas observações, isto é,

$$g(\mathbf{x}_{n+1}) \approx y_{n+1}, \dots, g(\mathbf{x}_{n+m}) \approx y_{n+m}$$

Função de risco em classificação

Regressão

$$R(g) = \mathbb{E}[(Y - g(\mathbf{x}))^2]$$

Classificação

$$R(g) = \mathbb{E}[\mathbb{I}(Y \neq g(\mathbf{x}))] = P(Y \neq g(\mathbf{x}))$$

ou seja, o risco de g é agora a probabilidade de erro em uma nova observação $(\mathbf{x}, Y)$. Em outras palavras, uma função de perda mais adequada para o contexto de classificação é $L(g(\mathbf{x}), Y) = \mathbb{I}(Y \neq g(\mathbf{x}))$, a chamada **função de perda 0 – 1**.

No contexto de regressão, vimos que a função que minimiza $E[(Y - g(\mathbf{x}))^2]$ é dada pela função de regressão $r(x) = E[Y|\mathbf{x} = x]$.

Regra ótima de Bayes

Teorema: Suponha que definimos o risco de uma função de predição $g : \mathbb{R}^p \rightarrow \mathcal{C}$ via perda 0 – 1:

$$R(g) = P(Y \neq g(\mathbf{x})),$$

em que $(\mathbf{x}, Y)$ é uma nova observação que não foi usada para estimar g . Então a função g que minimiza $R(g)$ é dada por

$$g(x) = \arg \max_{d \in \mathcal{C}} P(Y = d \mid \mathbf{x})$$