

Atividade Avaliativa 2 — Métodos Locais e Kernels

EST335 — Métodos Estatísticos para Machine Learning

Prof. Tiago Martins Pereira

2028-06-09

Índice

Informações gerais	2
Objetivo	2
1. Conhecendo o problema — 2 pontos	2
1.1	3
1.2	3
2. Regressão KNN — 4 pontos	3
2.1 — Interpretação como ajuste local	3
2.2 — Escolha de k	4
2.3 — Flexibilidade	4
2.4 — Distância e variáveis irrelevantes	5
3. Nadaraya–Watson — 4 pontos	5
3.1 — Da vizinhança rígida aos pesos suaves	5
3.2 — Largura de banda	5
3.3 — Viés e variância	6
3.4 — Forma do kernel	6
4. Regressão polinomial local — 3 pontos	6
4.1	6
4.2	6
4.3	7
5. Comparação dos métodos locais — 3 pontos	7
5.1	7
5.2	7
5.3	7
6. Kernel Ridge e RKHS — 3 pontos	8
6.1	8

6.2	8
6.3 — Interpretação	8
7. Síntese crítica — 1 ponto	9
Critérios de avaliação	9
Observações importantes	10

Informações gerais

- **Valor:** 20 pontos
- **Liberção:** 30/09/2026
- **Entrega:** 11/10/2026
- **Arquivo de dados:** dados_a2.csv
- **Produto a entregar:** um único documento .qmd, acompanhado do arquivo renderizado em HTML ou PDF
- Todas as análises devem ser **reprodutíveis**
- Gráficos, tabelas e métricas devem ser acompanhados de **interpretação**
- A escolha de hiperparâmetros deve ser feita **sem utilizar o conjunto de teste**

Objetivo

Nesta atividade, você investigará métodos de regressão não paramétrica e sua relação com a ideia de **localidade, suavização e regularização**.

A análise deve permitir compreender empiricamente como a complexidade do estimador é controlada em diferentes métodos e como esse controle afeta o compromisso entre viés e variância.

Serão estudados:

1. regressão KNN;
2. regressão de Nadaraya–Watson;
3. regressão polinomial local;
4. Kernel Ridge Regression e sua conexão com RKHS.

O objetivo **não é apenas encontrar o menor erro de teste**, mas explicar por que os métodos apresentam comportamentos diferentes.

1. Conhecendo o problema — 2 pontos

A base contém uma variável resposta contínua y e quatro covariáveis x_1 , x_2 , x_3 e x_4 .

1.1

Faça uma análise exploratória inicial que contenha, no mínimo:

- dimensão da base;
- estatísticas descritivas;
- investigação de valores ausentes;
- gráficos de y em função de cada covariável.

1.2

Com base **somente na análise exploratória**, discuta:

- a. Há indícios de não linearidade?
- b. Todas as covariáveis parecem igualmente informativas?
- c. Por que uma relação não linear pode representar uma dificuldade para uma regressão linear global?

Não utilize os resultados dos modelos das seções seguintes para responder a esta questão.

2. Regressão KNN — 4 pontos

Considere inicialmente apenas a covariável x_1 .

2.1 — Interpretação como ajuste local

Mostre que a previsão KNN em um ponto x_0 ,

$$\hat{g}(x_0) = \frac{1}{k} \sum_{i \in N_k(x_0)} y_i,$$

é equivalente à solução do problema de mínimos quadrados local

$$\hat{\beta}_0(x_0) = \arg \min_{\beta_0} \sum_{i \in N_k(x_0)} (y_i - \beta_0)^2.$$

Interprete o resultado. Em que sentido o KNN pode ser visto como uma **regressão local de grau zero**?

2.2 — Escolha de k

Separe os dados em **treino (80%) e teste (20%)**, utilizando uma semente fixa.

Usando **somente o conjunto de treino**, escolha k por validação cruzada com 10 folds.

Considere uma grade suficientemente ampla para evidenciar modelos muito flexíveis e muito suavizados.

Apresente:

- gráfico do erro de validação em função de k ;
- valor de k selecionado;
- justificativa da escolha.

2.3 — Flexibilidade

Compare graficamente pelo menos três valores de k :

- um pequeno;
- o selecionado por validação cruzada;
- um grande.

Explique o comportamento observado em termos de

$$k \downarrow \implies \text{flexibilidade} \uparrow$$

e

$$k \uparrow \implies \text{suavização} \uparrow .$$

2.4 — Distância e variáveis irrelevantes

Repita o KNN usando:

1. apenas x_1 ;
2. x_1 e x_2 ;
3. x_1 , x_2 , x_3 e x_4 .

Padronize as covariáveis antes de calcular distâncias.

Escolha k por validação cruzada em cada caso e compare o desempenho no conjunto de teste.

Discuta por que adicionar covariáveis pode **piorar** um método baseado em distância, mesmo quando há mais informação disponível.

3. Nadaraya–Watson — 4 pontos

Considere novamente inicialmente apenas x_1 .

O estimador de Nadaraya–Watson pode ser escrito como

$$\hat{g}_h(x_0) = \frac{\sum_{i=1}^n K\left(\frac{x_i - x_0}{h}\right) y_i}{\sum_{i=1}^n K\left(\frac{x_i - x_0}{h}\right)}.$$

3.1 — Da vizinhança rígida aos pesos suaves

Explique a principal diferença entre os pesos atribuídos às observações pelo KNN e pelo estimador de Nadaraya–Watson.

Relacione sua resposta à ideia de **localidade**.

3.2 — Largura de banda

Implemente o estimador utilizando kernel Gaussiano e escolha a largura de banda h por validação cruzada no conjunto de treino.

Apresente:

- grade de valores investigados;
- erro de validação;
- h selecionado.

3.3 — Viés e variância

Construa estimativas usando:

- um h menor que o selecionado;
- o h selecionado;
- um h substancialmente maior.

Apresente as três curvas juntamente com os dados e interprete-as em termos de viés, variância e suavização.

3.4 — Forma do kernel

Mantendo uma comparação coerente, confronte o kernel Gaussiano com pelo menos **um segundo kernel** (por exemplo, uniforme, triangular ou Epanechnikov).

Discuta: a escolha da forma do kernel parece ser mais ou menos importante que a escolha de h nesta aplicação?

4. Regressão polinomial local — 3 pontos

4.1

Ajuste, utilizando $\mathbf{x}_1$, uma regressão local de:

- grau 0;
- grau 1.

Use um procedimento de validação para selecionar o parâmetro de suavização de cada modelo.

4.2

Compare as curvas estimadas, dando atenção especial às regiões próximas às fronteiras do domínio de $\mathbf{x}_1$.

Explique por que o ajuste linear local pode reduzir o **viés de fronteira** em relação ao ajuste local constante.

4.3

Compare os resultados desta seção com KNN e Nadaraya–Watson. Identifique semelhanças e diferenças na maneira como os três métodos constroem uma previsão em x_0 .

5. Comparação dos métodos locais — 3 pontos

Compare os melhores modelos obtidos nas seções anteriores utilizando o **mesmo conjunto de teste**.

Apresente pelo menos:

- RMSE;
- MAE;
- gráfico observado versus predito;
- gráfico dos resíduos.

5.1

Existe um método claramente superior em todos os critérios?

5.2

Analise o erro ao longo do domínio de $\mathbf{x}_1$. O comportamento dos métodos é homogêneo ou existem regiões em que determinados estimadores apresentam maior dificuldade?

5.3

Construa uma síntese relacionando explicitamente:

k , h , flexibilidade, viés, variância.

6. Kernel Ridge e RKHS — 3 pontos

Nesta seção utilize `x1` e `x2`.

Considere Kernel Ridge Regression com kernel Gaussiano/RBF.

6.1

Selecione os hiperparâmetros por validação cruzada no conjunto de treino. Em particular, investigue o papel:

- do parâmetro do kernel que controla a escala/localidade;
- do parâmetro de regularização λ .

6.2

Apresente o desempenho no conjunto de teste e compare-o com os resultados anteriores.

6.3 — Interpretação

Considere o problema

$$\hat{f} = \arg \min_{f \in \mathcal{H}} \left\{ \frac{1}{n} \sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \|f\|_{\mathcal{H}}^2 \right\}.$$

Explique:

- a. o papel do primeiro termo;
- b. o papel de $\lambda \|f\|_{\mathcal{H}}^2$;
- c. o que tende a acontecer quando $\lambda \rightarrow 0$;
- d. o que tende a acontecer quando λ aumenta.

Por fim, estabeleça uma conexão conceitual entre Ridge e Kernel Ridge:

Ridge $\longrightarrow$ penalização dos coeficientes

e

Kernel Ridge $\rightarrow$ penalização da complexidade de f .

7. Síntese crítica — 1 ponto

Escreva uma conclusão de aproximadamente **200 a 300 palavras**, sem tópicos, respondendo:

O que controla a complexidade de um método não paramétrico e por que não existe um único nível de suavização adequado para todos os problemas?

Sua resposta deve fazer referência aos resultados obtidos na atividade e estabelecer relações entre KNN, kernels, regressão local e regularização.

Critérios de avaliação

Critério	Pontos
Exploração e compreensão do problema	2
KNN	4
Nadaraya–Watson	4
Regressão polinomial local	3
Comparação dos métodos locais	3
Kernel Ridge / RKHS	3
Síntese crítica	1
Total	20

Além da correção numérica, serão considerados:

- coerência metodológica;
- separação adequada entre treino, validação e teste;
- justificativa dos hiperparâmetros;
- qualidade dos gráficos;
- interpretação estatística;
- clareza e organização;
- reprodutibilidade.

Observações importantes

1. O conjunto de **teste não deve ser utilizado para escolher hiperparâmetros**.
2. Resultados sem interpretação terão pontuação reduzida.
3. Não basta informar qual método apresentou menor RMSE; é necessário explicar o comportamento observado.
4. Toda fonte externa, pacote ou código adaptado deve ser devidamente indicado.
5. O uso de ferramentas computacionais não substitui a justificativa estatística das escolhas realizadas.