Parte 1 : Regressão

Introdução

Introdução

O que é Aprendizagem?

- **Definição de aprendizagem:** É uma mudança adaptativa no comportamento causada pela experiência.

O que é Aprendizagem?

- **Definição de aprendizagem:** É uma mudança adaptativa no comportamento causada pela experiência.
- Praticamente todos os animais com sistema nervoso central são capazes de aprender (mesmo os mais simples).

O que é Aprendizagem?

- **O que significa para um computador aprender? Por que queremos que ele aprenda? Como fazemos para que ele aprenda?**
  - Queremos que computadores aprendam quando é muito difícil ou muito caro programá-los diretamente para executar uma tarefa.
  - Fazemos o computador "programar a si mesmo" ao mostrar exemplos de entradas e saídas.
    - Na prática, escrevemos um programa "parametrizado" e deixamos que o algoritmo de aprendizagem encontre o conjunto de parâmetros que melhor aproxima a função ou o comportamento desejado.

Definições Clássicas de Aprendizado de Máquina

Arthur Samuel (1959):

"Aprendizado de Máquina é o campo de estudo que dá aos computadores a habilidade de aprender sem serem explicitamente programados."

Definições Clássicas de Aprendizado de Máquina

Arthur Samuel (1959):

"Aprendizado de Máquina é o campo de estudo que dá aos computadores a habilidade de aprender sem serem explicitamente programados."

Tom Mitchell (1997):

"Dizemos que um programa de computador aprende a partir de uma experiência E, com respeito a alguma tarefa T e alguma medida de desempenho P, se o seu desempenho na tarefa T, medido por P, melhora com a experiência E."

Definições Clássicas de Aprendizado de Máquina

- T — **Task (Tarefa):** A tarefa que queremos resolver.
  - Exemplos:
    - classificar e-mails, prever preço de casas, detectar fraude

Definições Clássicas de Aprendizado de Máquina

- T — **Task (Tarefa):** A tarefa que queremos resolver.
  - Exemplos:
    - classificar e-mails, prever preço de casas, detectar fraude
- E — **Experience (Experiência):** Os dados utilizados para aprender.
  - Exemplo:
    - histórico de e-mails rotulados como **spam** ou **não spam**

Definições Clássicas de Aprendizado de Máquina

- T — **Task (Tarefa):** A tarefa que queremos resolver.
  - Exemplos:
    - classificar e-mails, prever preço de casas, detectar fraude
- E — **Experience (Experiência):** Os dados utilizados para aprender.
  - Exemplo:
    - histórico de e-mails rotulados como **spam** ou **não spam**
- P — **Performance (Desempenho):** Métrica usada para avaliar o modelo.
  - Exemplos:
    - acurácia, erro quadrático médio, AUC

Por que precisamos de Aprendizado de Máquina?

É muito difícil resolver problemas como o **reconhecimento de objetos bidimensionais ou tridimensionais**.

- Não sabemos qual programa escrever, pois **não sabemos exatamente como o cérebro realiza essa tarefa**.
- Mesmo que soubéssemos, **o programa provavelmente seria extremamente complexo**.

Exemplo: reconhecimento de dígitos manuscritos

Um exemplo clássico é o reconhecimento automático de **dígitos escritos à mão**.

A variabilidade na forma como cada pessoa escreve os números torna muito difícil criar **regras explícitas de programação** para identificar cada dígito.

Em vez disso, usamos **aprendizado de máquina**, que permite ao algoritmo **aprender padrões diretamente a partir dos dados**.

Exemplo: dígitos manuscritos (MNIST)

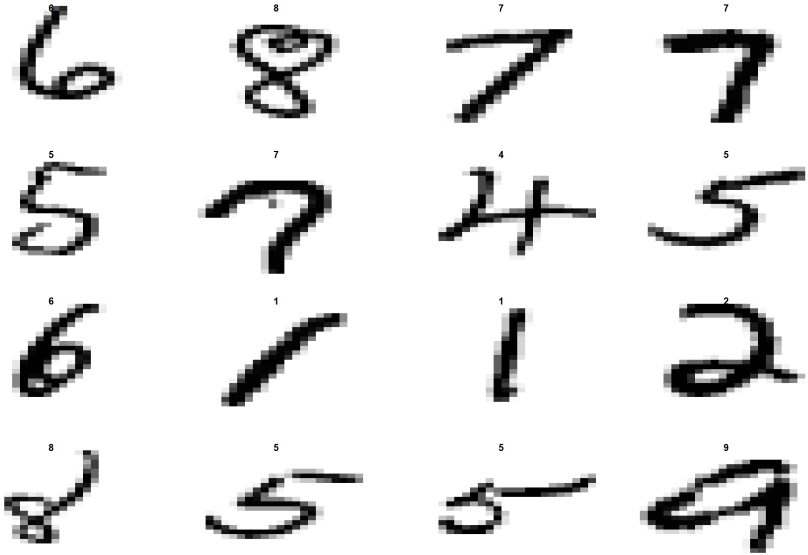

Por que precisamos de Aprendizado de Máquina?

A abordagem de aprendizado de máquina

Em vez de escrever um programa manualmente, coletamos **muitos exemplos** que especificam a saída correta para uma determinada entrada.
Um **algoritmo de aprendizado de máquina** produz um programa a partir desses dados.

- O programa produzido por um algoritmo de aprendizado pode ser **muito diferente de um programa típico escrito manualmente**.
- Se fizermos isso corretamente, o programa **funciona para novos casos**, além daqueles usados no treinamento.

Observação importante

Grandes quantidades de computação e dados hoje são mais baratas do que pagar alguém para escrever um programa manualmente.

Programação Tradicional vs Aprendizado de Máquina

Programação tradicional

Nós escrevemos explicitamente as regras.

Entrada + Regras $\rightarrow$ Saída

Exemplo:

- **Entrada:** dados de um cliente
- **Regras:** lógica escrita pelo programador
- **Saída:** decisão do sistema

Aprendizado de máquina

O algoritmo aprende as regras a partir dos dados.
Entrada + Saída $\rightarrow$ Algoritmo $\rightarrow$ Modelo
Exemplo:

- **Dados:** histórico de clientes
- **Respostas:** compra / não compra
- **Modelo aprendido:** sistema de previsão

Diferentes Tipos de Aprendizado

Aprendizado Supervisionado

Entrada $\rightarrow$ Saída conhecida

Exemplos:

- classificação de imagens
- previsão de preços
- detecção de spam

Aprendizado Não Supervisionado

Somente entradas disponíveis

Objetivo:

- descobrir padrões ocultos
- identificar grupos

Exemplos:

- **clusterização**
- **redução de dimensionalidade**

Aprendizado por Reforço

Agente interage com um ambiente

Componentes:

- **estado**
- **ação**
- **recompensa**

Exemplos:

- robôs
- jogos
- veículos autônomos

Supervisionado

↓

Classificação
Regressão

Não Supervisionado

↓

Clusterização
Redução de Dimensão

Reforço

↓

Aprendizado de Políticas

Aprendizado Supervisionado

Notação e Suposições

No **aprendizado supervisionado**, dispomos de um conjunto de treinamento:

$$\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$$

onde:

- $x_i = (x_{i1}, \dots, x_{id})$ representa as **variáveis explicativas**
- y_i representa a **variável resposta observada**

A partir dos dados de treinamento, queremos aprender uma função $g(\mathbf{x})$ capaz de prever a resposta para **novas observações**.

A partir dos dados de treinamento, queremos aprender uma função $g(\mathbf{x})$ capaz de prever a resposta para **novas observações**.

Quando Y é **quantitativa**, buscamos aproximar a **função de regressão**

$$r(\mathbf{x}) = \mathbb{E}[Y \mid X = \mathbf{x}]$$

que descreve a relação entre

- uma variável resposta $Y \in \mathbb{R}$
- um vetor de covariáveis

$$\mathbf{x} = (x_1, \dots, x_p) \in \mathbb{R}^p$$

Formulação do aprendizado estatístico

Uma forma comum de representar o problema é

$$Y = r(\mathbf{x}) + \varepsilon$$

onde:

- $r(\mathbf{x})$ é a **função verdadeira desconhecida**
- ε representa **ruído aleatório**
- $\mathbb{E}[\varepsilon \mid X] = 0$

O objetivo do **aprendizado supervisionado** é **estimar** (treinar) uma aproximação

$$g(\mathbf{x}) \approx r(\mathbf{x})$$

Predição versus Inferência: Por que estimar f(x)?

Exemplo 1.1 — Expectativa de vida e PIB per capita

Considere dados de **211 países no ano de 2012**, contendo:

- **PIB per capita**
- **expectativa de vida**

Uma pergunta natural é:

> *Como podemos usar esses dados para **estabelecer uma relação entre essas duas variáveis**?*

Objetivo

Queremos usar os dados para **estimar a expectativa de vida de um país** quando seu **PIB per capita é conhecido**.
Formalmente, queremos estimar

$$\mathbb{E}[Y \mid X = x]$$

onde

- $Y =$ expectativa de vida de um país
- $X =$ PIB per capita

Interpretação da função de regressão

A quantidade

$$\mathbb{E}[Y \mid X = x]$$

representa a **expectativa de vida média esperada para países com PIB per capita igual a** x.

Estimando essa função podemos:

- **prever expectativa de vida** a partir do PIB per capita
- **investigar a relação entre as variáveis**
- **testar a hipótese de que não existe relação entre elas**

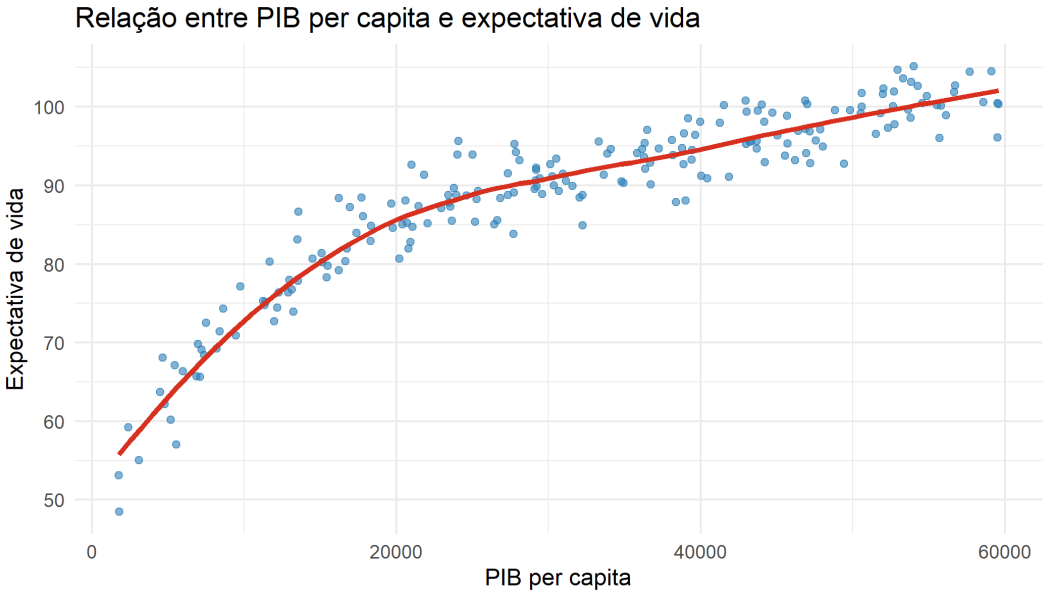
Relação entre PIB per capita e expectativa de vida
Expectativa de vida
100
90
80
70
60
50
0
20000
40000
60000
PIB per capita

Predição versus Inferência: Por que estimar f(x)?

Exemplo 1.2 — Distância de uma galáxia até a Terra

Na cosmologia, uma variável extremamente importante é o **desvio para o vermelho** (*redshift*) de uma galáxia.
Esse valor mede **quão distante a galáxia está da Terra**.

O problema

O **redshift** pode ser medido com grande precisão por meio de **espectroscopia**.
No entanto:

- esse procedimento é **caro**
- exige **muito tempo de observação**

Por isso, surge a seguinte pergunta:

*Podemos estimar o **redshift** utilizando apenas **imagens das galáxias**?*

Formulação como aprendizado supervisionado

Considere uma amostra de treinamento

$$(\mathbf{x}_1, Y_1), \ldots, (\mathbf{x}_n, Y_n)$$

onde

- $\mathbf{x}_i$ = imagem da i-ésima galáxia
- Y_i = redshift medido por espectroscopia

Objetivo

Queremos estimar a **função de regressão**

$$r(x) = \mathbb{E}[Y \mid X = \mathbf{x}]$$

A partir dessa função podemos:

- prever o **redshift** de novas galáxias
- estimar suas **distâncias até a Terra**

Predição versus Inferência: Por que estimar f(x)?

Exemplo 1.3 — Isomap Face Data

Neste conjunto de dados, proveniente de Tenenbaum, Silva, and Langford (2000), o objetivo é estimar **a direção para a qual uma pessoa está olhando**.

- **Resposta (Y):** direção do olhar
- **Covariáveis ($\mathbf{x}$):** imagem da face da pessoa

Formulação do problema

Uma forma de resolver esse problema é estimar a **função de regressão**

$$r(x) = \mathbb{E}[Y \mid X = \mathbf{x}]$$

utilizando uma amostra de treinamento

$$(\mathbf{x}_1, Y_1), \ldots, (\mathbf{x}_n, Y_n)$$

onde:

- $\mathbf{x}_i$ = imagem da face do indivíduo
- Y_i = direção do olhar

Predição em novas imagens

Depois de estimar a função $r(\mathbf{x})$, podemos utilizá-la para

- prever a **direção do olhar** em novas imagens
- inferir a variável resposta Y a partir das covariáveis $\mathbf{x}$

Em outras palavras:
imagem da face $\rightarrow$ modelo $\rightarrow$ direção do olhar

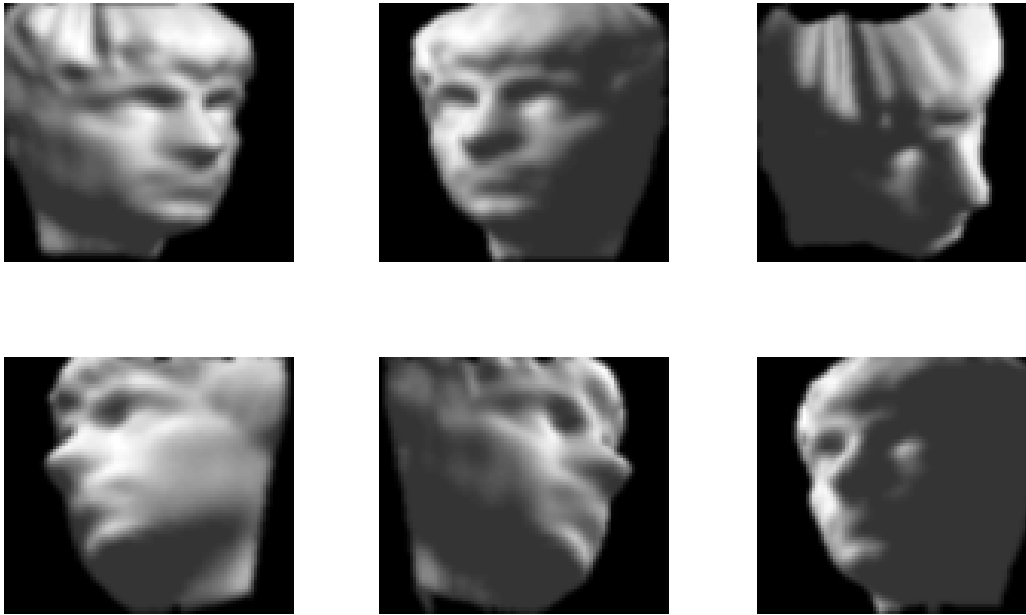

Predição versus Inferência: Por que estimar f(x)?

Exemplo 1.4 — Predição do ano de lançamento de músicas

Os dados do **YearPredictionMSD** contêm diversas covariáveis sobre músicas do banco **Million Song Dataset**.

Alguns exemplos de variáveis:

- características de **timbre**
- **energia** da música
- **dançabilidade**
- outras características acústicas

Além disso, o conjunto de dados contém o **ano de lançamento** de cada música.

Formulação como problema de regressão

Considere

- $\mathbf{x}$ = vetor de características da música
- Y = ano de lançamento

Queremos estimar a **função de regressão**

$$r(x) = \mathbb{E}[Y \mid X = x]$$

ou seja, o **ano esperado de lançamento dado o conjunto de características da música**.

O que podemos fazer com esse modelo?

Uma estimativa de $r(x)$ pode ser usada para:

1. **Predição**

Prever o ano de lançamento de novas músicas a partir de suas características

2. **Interpretação**

Investigar quais características musicais estão associadas ao ano de lançamento

MÚSICAS DOS ANOS 70 ERAM MAIS DANÇÁVEIS?
MÚSICAS RECENTES POSSUEM MAIOR ENERGIA?
QUANTOS TIPOS DE MÚSICA EXISTEM NO MUNDO?

Interpretação em aprendizado supervisionado

Temos uma amostra de treinamento

$$(\mathbf{x}_1, Y_1), \dots, (\mathbf{x}_n, Y_n)$$

onde:

- $\mathbf{x}_i$ = características da música
- Y_i = ano de lançamento

O objetivo é aprender uma função $g(x)$ capaz de prever o **ano de lançamento de novas músicas**.

Dois objetivos do aprendizado supervisionado

De modo geral, os problemas apresentados podem ser divididos em **dois objetivos principais**.

Objetivo inferencial

Perguntas típicas:

- Quais **preditores** são importantes?
- Qual é a **relação entre cada preditor e a variável resposta**?
- Qual é o **efeito de mudar o valor de um preditor** na variável resposta?

Esse tipo de análise busca **interpretar a relação entre as variáveis**.

Objetivo preditivo

Queremos construir uma função

$$g : \mathbb{R}^p \to \mathbb{R}$$

com **bom poder preditivo**.
A ideia é encontrar uma função g tal que, para novas observações i.i.d.

$$(X_{n+1}, Y_{n+1}), \dots, (X_{n+m}, Y_{n+m}),$$

tenhamos boas aproximações

$$g(x_{n+1}) \approx y_{n+1}, \dots, g(x_{n+m}) \approx y_{n+m}$$

Duas culturas em modelagem estatística

Breiman (2001) argumenta que existem duas culturas no uso de modelos estatísticos (em especial modelos de regressão).

Data Modeling Culture

- Domina a **comunidade estatística**.
- O principal objetivo está na **interpretação dos parâmetros**.
- **Testar suposições do modelo** é fundamental.

Foco:

- **Inferência**
- Compreensão do mecanismo gerador dos dados

Algorithmic Modeling Culture

- Domina a **comunidade de Machine Learning**.
- O foco está em **obter bons algoritmos preditivos**.
- Os resultados podem ser interpretados, mas **isso geralmente não é o foco principal**.

Foco:

- **Predição**
- Desempenho em novos dados

Integração entre Estatística e Machine Learning

Machine Learning e Estatística não são opostos: são complementares.

Historicamente, as duas áreas enfatizaram objetivos diferentes:

- **Estatística:** foco em **inferência e interpretação** dos modelos.
- **Machine Learning:** foco em **predição e desempenho em novos dados**.

Tendência atual

Hoje muitos métodos modernos procuram **combinar as duas culturas**, buscando:

- **alto desempenho preditivo**
- **interpretação dos modelos**

Exemplos:

- **Random Forest interpretável**
- **SHAP (Shapley Additive Explanations)**
- **modelos semiparamétricos:** GAM (Modelos aditivos generalizados), Modelo de Cox (riscos proporcionais), etc.

Regressão linear

modelo paramétrico
simples e interpretável
baixa flexibilidade

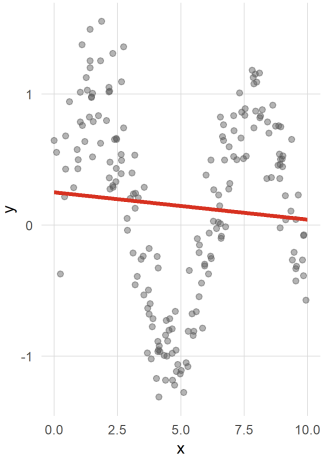

GAM

modelo semiparamétrico
mantém interpretabilidade
permite relações não lineares

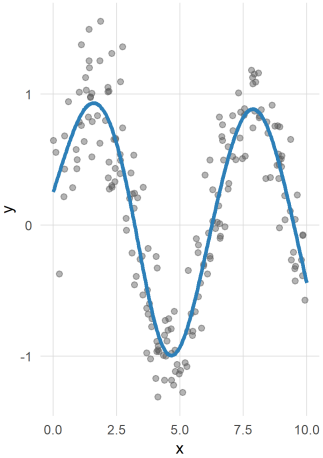

Árvore de decisão

modelo algorítmico
muito flexível
foco em predição

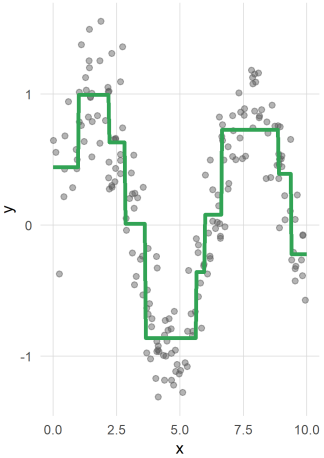

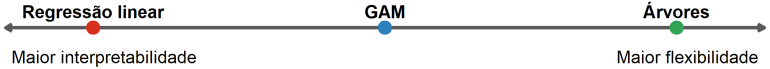

Interpretabilidade *vs.* Flexibilidade

Em modelagem estatística e aprendizado de máquina, frequentemente existe um **trade-off entre interpretabilidade e flexibilidade**.

- **Interpretabilidade:** facilidade de compreender como o modelo toma decisões.
- **Flexibilidade:** capacidade do modelo de capturar padrões complexos nos dados.

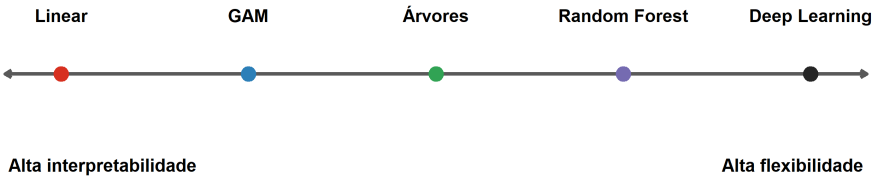

Modelos mais simples tendem a ser **mais interpretáveis**, enquanto modelos mais complexos tendem a ser **mais flexíveis** e capazes de capturar padrões não lineares.

Em muitos problemas aplicados, o objetivo é encontrar um **equilíbrio entre interpretação e desempenho preditivo**.

A Função de Risco

Para construir boas funções de predição, precisamos de um **critério para medir o desempenho** de uma função de predição

$$g : \mathbb{R}^p \to \mathbb{R}$$

Em problemas de regressão, um critério muito utilizado é o **risco quadrático**, definido como

$$R(g) = \mathbb{E}\left[(Y - g(\mathbf{x}))^2\right]$$

onde $(\mathbf{x}, Y)$ representa **uma nova observação**, não utilizada para estimar g. Quanto **menor o risco**, **melhor** é a função de predição g.

O objetivo do aprendizado estatístico é encontrar uma função g que **minimize esse risco**.

Na prática, queremos encontrar

$$g^* = \arg\min_g R(g)$$

Essa função é chamada de **preditor ótimo**.

Função de perda

Para avaliar a qualidade de uma função de predição $g(\mathbf{x})$, utilizamos uma **função de perda**.

Uma escolha comum em problemas de regressão é a **perda quadrática**

$$L(g(X), Y) = (Y - g(\mathbf{x}))^2$$

Essa função mede o **erro entre o valor observado** Y **e a predição** $g(\mathbf{x})$.

Outras funções de perda

Além da perda quadrática, outras funções de perda podem ser utilizadas.
Por exemplo, a **perda absoluta**

$$L(g(\mathbf{x}), Y) = |Y - g(\mathbf{x})|$$

Diferentes funções de perda levam a **diferentes critérios de ajuste do modelo**.

O risco de predição

De forma geral, o **risco** de uma função de predição é definido como

$$R(g) = \mathbb{E}[L(g(\mathbf{x}), Y)]$$

Ou seja, o risco corresponde ao **valor esperado da função de perda**.
O objetivo é encontrar uma função g que minimize o risco

$$g^* = \arg\min_g \mathbb{E}[L(g(\mathbf{x}), Y)]$$

Em outras palavras, queremos um modelo que produza **erros pequenos em média para novas observações**.

Decomposição do erro de predição

Considere uma função de predição

$$g : \mathbb{R}^p \to \mathbb{R}$$

O risco de predição sob perda quadrática é

$$R_{pred}(g) = \mathbb{E}[(Y - g(\mathbf{x}))^2]$$

Este risco mede **o erro médio de predição para novas observações**.

Erro em relação à função de regressão

Lembre que a função de regressão é

$$r(x) = \mathbb{E}[Y \mid X = \mathbf{x}]$$

Podemos então medir o erro do modelo em relação à função verdadeira:

$$R_{reg}(g) = \mathbb{E}[(r(\mathbf{x}) - g(\mathbf{x}))^2]$$

Teorema

Sob perda quadrática,

$$R_{pred}(g) = R_{reg}(g) + \mathbb{E}[\mathrm{Var}(Y|\mathbf{x})]$$

Demonstração

$$
\begin{aligned}
\mathbb{E}\left[(Y-g(\mathbf{x}))^2\right] &= \mathbb{E}\left[(Y-r(\mathbf{x})+r(\mathbf{x})-g(\mathbf{x}))^2\right] \\
&= \mathbb{E}\left[(r(\mathbf{x})-g(\mathbf{x}))^2\right] + \mathbb{E}\left[(Y-r(\mathbf{x}))^2\right] + 2\,\mathbb{E}\left[(r(\mathbf{x})-g(\mathbf{x}))(Y-r(\mathbf{x}))\right] \\
&= \mathbb{E}\left[(r(\mathbf{x})-g(\mathbf{x}))^2\right] + \mathbb{E}\left[\mathrm{Var}(Y|\mathbf{x})\right]
\end{aligned}
$$

em que o último passo segue do fato que (lei da esperança total)

$$
\mathbb{E}\left[(r(\mathbf{x})-g(\mathbf{x}))(Y-r(\mathbf{x}))\right] = \mathbb{E}\left[\mathbb{E}\left[(r(\mathbf{x})-g(\mathbf{x}))(Y-r(\mathbf{x}))\mid \mathbf{x}\right]\right] = 0
$$

e

$$
\mathbb{E}\left[(Y-r(\mathbf{x}))^2\right] = \mathbb{E}\left[\mathbb{E}\left[(Y-r(\mathbf{x}))^2\mid \mathbf{x}\right]\right] = \mathbb{E}\left[\mathrm{Var}(Y|\mathbf{x})\right],
$$

pois $r(\mathbf{x}) = \mathbb{E}[Y|\mathbf{x}]$.

Assim, o erro de predição pode ser decomposto em duas partes:

Erro de aproximação do modelo

$$R_{reg}(g) = \mathbb{E}[(r(\mathbf{x}) - g(\mathbf{x}))^2]$$

mede **o quão bem o modelo aproxima a função verdadeira**.

Ruído irreduzível

$$\mathbb{E}[\mathrm{Var}(Y \mid \mathbf{x})]$$

representa a **variabilidade intrínseca dos dados**, que **nenhum modelo consegue reduzir**.

Observação: risco condicional *vs.* risco esperado

A função de predição g pode ser entendida de duas formas.

Função fixa

Depois que a amostra de treinamento é observada, obtemos uma função de predição

$$g = g_n$$

Nesse caso, tratamos g como fixa e avaliamos seu risco em uma nova observação (X, Y):

$$R(g) = \mathbb{E}\left[(Y - g(\mathbf{x}))^2\right]$$

Esse risco é chamado de **risco condicional**.

Quando g depende dos dados

Antes de observar a amostra, a função de predição ainda não está determinada. Na prática, ela é construída a partir dos dados de treinamento

$$(\mathbf{x}_1, Y_1), \dots, (\mathbf{x}_n, Y_n)$$

Portanto, o modelo ajustado deve ser escrito como

$$g = g((\mathbf{x}_1, Y_1), \dots, (\mathbf{x}_n, Y_n)),$$

ou, de forma abreviada,

$$g = g(\mathcal{D}_n),$$

onde $\mathcal{D}_n$ representa a amostra de treinamento.

Como g depende da amostra, ele é uma **função aleatória dos dados**.

Nesse caso, podemos considerar a esperança também em relação à amostra de treinamento.

Assim, o **risco esperado** é a média do risco condicional sobre todas as possíveis amostras:

$$\mathbb{E}_{\mathcal{D}_n}\left[R(g(\mathcal{D}_n))\right]$$

Equivalentemente,

$$\text{Risco esperado} = \mathbb{E}[\text{risco condicional}]$$

Interpretação

- O **risco condicional** avalia o desempenho de um modelo específico, já ajustado.
- O **risco esperado** avalia o desempenho médio do procedimento de aprendizado.

Ou seja:

- risco condicional $\rightarrow$ garantia sobre uma função g específica
- risco esperado $\rightarrow$ garantia sobre o algoritmo que constrói g

Exemplo

Suponha que o **risco esperado da regressão linear** em um problema seja igual a C. Isso significa que, **em média**, ao aplicar **regressão linear** a **diferentes amostras provenientes da mesma distribuição e com o mesmo tamanho amostral**, o **risco condicional** obtido será aproximadamente C.

Seleção de Modelos: Super e Sub-Ajuste

Em problemas práticos, é comum ajustar **vários modelos candidatos** para aproximar a função de regressão $r(x)$.

O objetivo é identificar qual modelo possui **maior poder preditivo**.

Exemplo: expectativa de vida e PIB per capita

Considere o problema de prever a **expectativa de vida** de um país a partir de seu **PIB per capita**.

A função de predição considerada é

$$g(x) = \beta_0 + \sum_{i=1}^{p} \beta_i x^i$$

onde

$$p \in \{1, 4, 50\}$$

Modelos considerados

Ajustamos três **regressões polinomiais**:

- modelo de **grau 1**
- modelo de **grau 4**
- modelo de **grau 50**

Os parâmetros β_i são estimados pelo **método dos mínimos quadrados**.

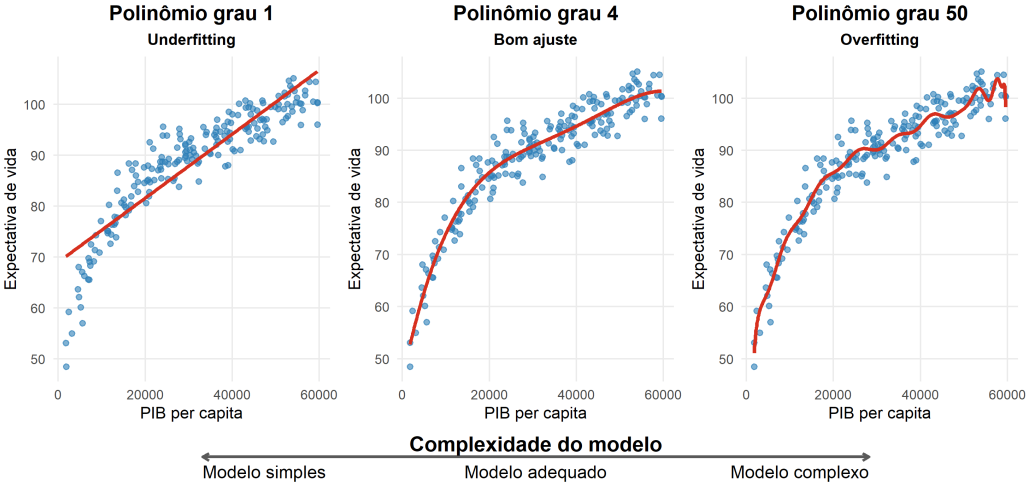
Polinômio grau 1
Underfitting
Polinômio grau 4
Bom ajuste
Polinômio grau 50
Overfitting
Expectativa de vida
PIB per capita
50
60
70
80
90
100
0
20000
40000
60000
Complexidade do modelo
Modelo simples
Modelo adequado
Modelo complexo

Comparação de modelos

- O modelo de **grau 1** é **simples demais** para capturar a relação.
- O modelo de **grau 50** é **extremamente complexo** e se ajusta demais aos dados.
- O modelo de **grau 4** oferece um **compromisso razoável entre flexibilidade e estabilidade**.

Underfitting e Overfitting

Sub-ajuste (Underfitting)

O modelo com $p = 1$ **não captura bem o padrão dos dados**.

Super-ajuste (Overfitting)

O modelo com $p = 50$ **se ajusta demais à amostra observada** e tende a produzir **más predições para novos dados**.

Objetivo

O objetivo é encontrar um modelo **intermediário**, que apresente bom desempenho preditivo.
Neste exemplo, gostaríamos de um método que **escolha automaticamente** $p = 4$.

Seleção de modelos

O objetivo de um método de **seleção de modelos** é escolher uma boa função de predição g.

Para isso, utilizamos um critério que permita avaliar a qualidade preditiva da função.

Neste contexto, usamos o **risco quadrático** para medir a qualidade do modelo $R(g)$.

Queremos então escolher uma função g dentro de uma classe de candidatos $\mathcal{G}$ que apresente **baixo risco quadrático**.

Objetivo prático

Ao selecionar um modelo, queremos evitar:

- **sub-ajuste (underfitting)**
- **super-ajuste (overfitting)**

Ou seja, buscamos um modelo com **bom poder preditivo** para novas observações.

Desafio

Na prática, o valor de $R(g)$ é **desconhecido**.
Por isso, precisamos **estimar o risco** para avaliar e comparar as funções $g \in \mathcal{G}$.

Próximo passo

A questão central passa a ser:

> *Como estimar o risco de predição de um modelo?*

Na próxima etapa, estudamos métodos para **estimar esse risco** e, assim, escolher o modelo mais adequado.

Data Splitting e Validação Cruzada

Risco observado

Uma forma natural de avaliar um modelo é medir seu erro **nos dados de treinamento**. Esse erro é chamado de **risco observado** ou **erro quadrático médio (EQM)** no conjunto de treinamento:

$$EQM(g) = \frac{1}{n}\sum_{i=1}^{n}(Y_i - g(\mathbf{x}_i))^2$$

Interpretação

O $EQM(g)$ mede o quão bem o modelo ajusta **os dados observados**

$$(\mathbf{x}_1, Y_1), \dots, (\mathbf{x}_n, Y_n)$$

Quanto menor o valor de $EQM(g)$, melhor o modelo se ajusta **à amostra de treinamento**.

Problema

O risco observado é um estimador **muito otimista** do verdadeiro risco de predição. Isso ocorre porque o modelo g foi ajustado **utilizando os próprios dados de treinamento**.

Consequência

Se utilizarmos apenas o erro de treinamento para escolher modelos, podemos obter:

- modelos **muito complexos**
- **super-ajuste (overfitting)**

ou seja, um modelo que se ajusta muito bem aos dados observados, mas apresenta **baixo poder de generalização**.
Minimizar apenas o erro de treinamento leva a **erro de treino muito baixo** mas **erro de predição alto em novos dados**.

Data splitting

Uma forma simples de estimar o risco de predição é **dividir o conjunto de dados em duas partes**: **Treinamento** e **Validação**

Por exemplo:

- **Treinamento (70%)**

$$(\mathbf{x}_1, Y_1), (\mathbf{x}_2, Y_2), \dots, (\mathbf{x}_s, Y_s)$$

- **Validação (30%)**

$$(\mathbf{x}_{s+1}, Y_{s+1}), \dots, (\mathbf{x}_n, Y_n)$$

Etapa 1: Ajustar o modelo

Utilizamos **apenas o conjunto de treinamento** para estimar a função de predição g. Por exemplo, podemos estimar os coeficientes de uma regressão linear.

Etapa 2: Avaliar o modelo

O conjunto de validação é utilizado **apenas para avaliar o modelo**.
Estimamos o risco através do erro quadrático médio no conjunto de validação:

$$\hat{R}(g) = \frac{1}{n-s} \sum_{i=s+1}^{n} (Y_i - g(\mathbf{x}_i))^2$$

Interpretação

Esse valor corresponde ao **erro quadrático médio no conjunto de validação**. Como os dados de validação **não foram usados para treinar o modelo**, essa estimativa é **mais próxima do verdadeiro erro de predição**.

Ideia central

Treinamos o modelo com um conjunto de dados e avaliamos sua performance em **dados não utilizados no treinamento**.
Isso nos ajuda a detectar **overfitting**.

Escolha das amostras

Uma boa prática ao dividir os dados em **treinamento** e **validação** é fazer essa divisão **aleatoriamente**.

Para isso, utilizamos um **gerador de números aleatórios** para selecionar quais observações irão compor cada conjunto.

Por que fazer a divisão aleatoriamente?

A seleção aleatória evita problemas quando o banco de dados está **ordenado de alguma forma**.

Por exemplo:

- observações ordenadas por tempo
- observações ordenadas por renda
- observações ordenadas por região

Se não embaralharmos os dados, os conjuntos podem ficar **enviesados**.

Resultado teórico

Como os dados de validação não foram usados no treinamento, o estimador $\hat{R}(g)$ é **consistente** para o verdadeiro risco $R(g)$ pela **Lei dos Grandes Números**.

Interpretação

À medida que o tamanho do conjunto de validação aumenta,

$$\hat{R}(g) \to R(g)$$

ou seja, o erro estimado converge para o **verdadeiro erro de predição**.

Problema: overfitting na validação

Se avaliarmos **muitos modelos diferentes**, podemos acabar escolhendo um modelo que se ajusta **bem ao conjunto de validação por acaso**.

Isso gera **super-ajuste ao conjunto de validação**.

Consequência:

- o modelo escolhido pode ter bom desempenho na validação, mas **não generalizar bem para novos dados**.

Treinamento *vs.* Validação *vs.* Teste

Uma prática comum é dividir os dados em três partes:

- **Treinamento** $\rightarrow$ ajustar os modelos
- **Validação** $\rightarrow$ escolher o melhor modelo
- **Teste** $\rightarrow$ avaliar o desempenho final

Interpretação

O conjunto de teste fornece uma estimativa do risco

$$R(g) = \mathbb{E}[(Y - g(\mathbf{x}))^2]$$

para **novas observações**. Assim podemos avaliar se o modelo escolhido realmente **generaliza bem**.

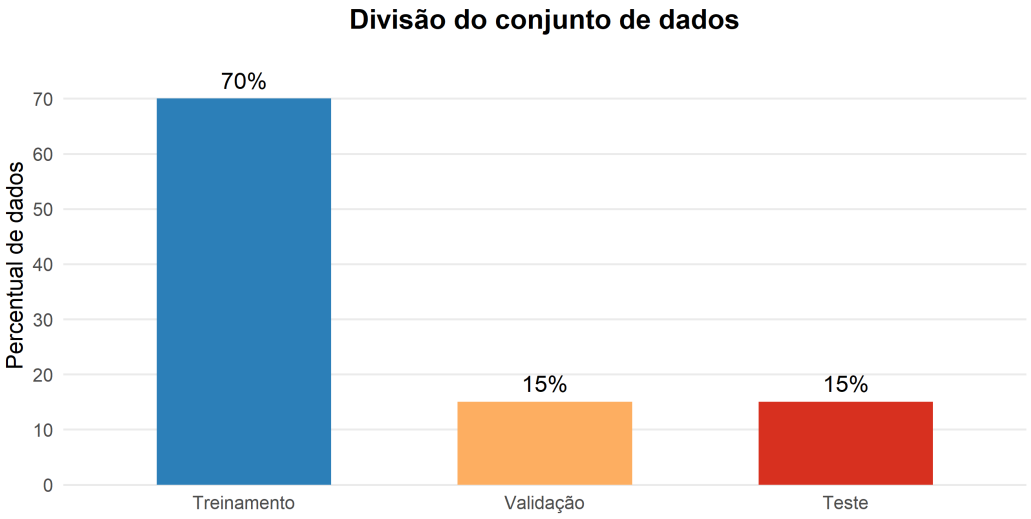
Divisão do conjunto de dados
Percentual de dados
70
60
50
40
30
20
10
0
70%
15%
15%
Treinamento
Validação
Teste

Validação cruzada

Uma variação desse método é a **validação cruzada**, que utiliza **toda a amostra** para avaliar o modelo.

Uma forma particular é o método **leave-one-out cross validation (LOOCV)**.

Leave-One-Out Cross Validation (LOOCV)

No LOOCV, ajustamos o modelo **n vezes**.
A cada passo:

- removemos uma observação do conjunto de dados
- ajustamos o modelo com as outras $n - 1$ observações
- avaliamos o erro na observação removida

Estimador do risco

O estimador do risco no LOOCV é dado por

$$\hat{R}(g) = \frac{1}{n}\sum_{i=1}^{n}(Y_i - g_{-i}(\mathbf{x}_i))^2$$

onde g_{-i} é o modelo ajustado **sem utilizar a i-ésima observação**.

Conjunto de treinamento em cada etapa

Para estimar g_{-i} utilizamos todas as observações **exceto a i-ésima**:

$$(\mathbf{x}_1, Y_1), \dots, (\mathbf{x}_{i-1}, Y_{i-1}), (\mathbf{x}_{i+1}, Y_{i+1}), \dots, (\mathbf{x}_n, Y_n)$$

Ideia central

Cada observação é usada:

- **uma vez para teste**
- $n - 1$ **vezes para treinamento**

Assim, o LOOCV utiliza **toda a informação disponível** para estimar o erro de predição.

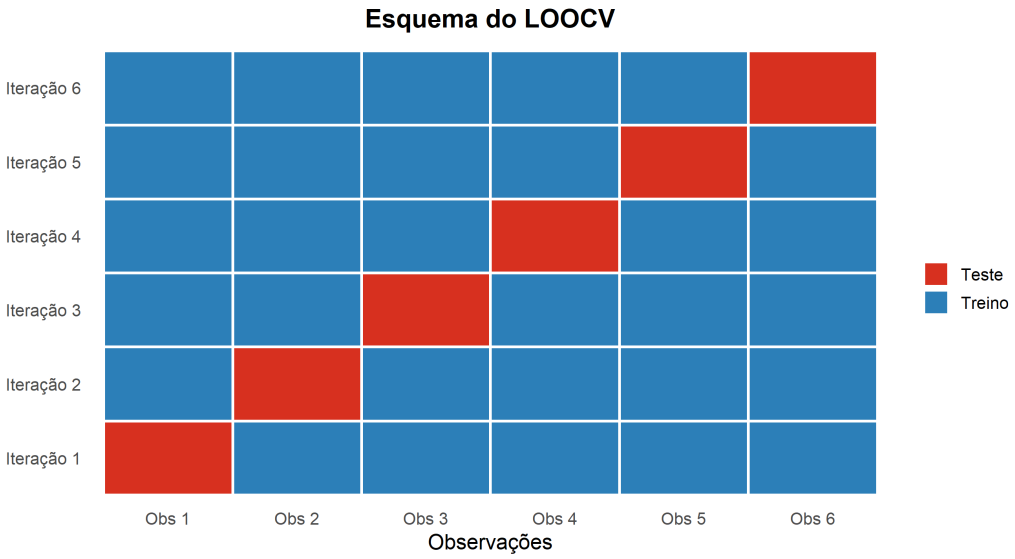
Esquema do LOOCV
Iteração 6
Iteração 5
Iteração 4
Iteração 3
Iteração 2
Iteração 1
Obs 1
Obs 2
Obs 3
Obs 4
Obs 5
Obs 6
Observações
Teste
Treino

k-fold cross-validation

Uma alternativa ao LOOCV é o método **k-fold cross-validation**.

Nesse procedimento, dividimos o conjunto de dados **aleatoriamente** em k subconjuntos disjuntos chamados **folds**, com aproximadamente o mesmo tamanho.

Divisão em folds

Denotamos por

$$L_1, L_2, \dots, L_k \subset \{1, \dots, n\}$$

os conjuntos de índices associados a cada fold.
Cada L_j representa um **subconjunto de observações** utilizado para validação.

Ajuste dos modelos

Para cada fold L_j:

- ajustamos o modelo utilizando **todas as observações exceto as de** L_j
- obtemos uma função estimada $\hat{g}_{-j}$ treinada sem as observações do j-ésimo fold.

Estimador do risco

O estimador do risco via k-fold cross-validation é

$$\hat{R}(g) = \frac{1}{n} \sum_{j=1}^{k} \sum_{i \in L_j} (Y_i - \hat{g}_{-j}(\mathbf{x}_i))^2$$

Interpretação

Cada fold é usado **uma vez para validação** e $k-1$ **vezes para treinamento**.
Assim, utilizamos **toda a amostra** para avaliar o desempenho do modelo.

Relação com LOOCV

Quando $k = n$ cada fold contém apenas **uma observação**.
Nesse caso, recuperamos o método **Leave-One-Out Cross Validation (LOOCV)**.

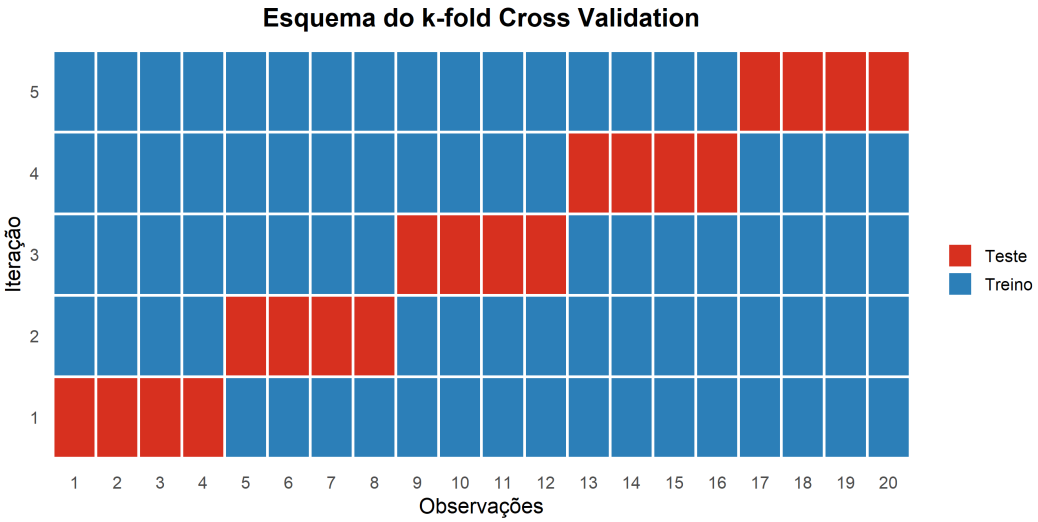
Esquema do k-fold Cross Validation
Iteração
5
4
3
2
1
1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20
Observações
Teste
Treino

LOOCV e erro esperado

Uma propriedade importante do **leave-one-out cross validation (LOOCV)** é que ele é aproximadamente **não viesado** para o **erro esperado** do método de aprendizagem.

Ou seja, ele fornece uma boa estimativa do desempenho médio do modelo em **novos dados**.

Intervalos de confiança para o risco

Depois de escolher o modelo usando **treinamento** e **validação**, utilizamos o **conjunto de teste** para estimar o risco verdadeiro do modelo.

O conjunto de teste não foi usado para ajustar o modelo.

Estimador do risco no conjunto de teste

Denote por $(\tilde{\mathbf{x}}_1, \tilde{Y}_1), \ldots, (\tilde{\mathbf{x}}_m, \tilde{Y}_m)$ as observações do **conjunto de teste**.
Um estimador do risco é

$$\hat{R}(g) = \frac{1}{m} \sum_{k=1}^{m} (\tilde{Y}_k - g(\tilde{\mathbf{x}}_k))^2$$

Definimos

$$W_k = (\tilde{Y}_k - g(\tilde{\mathbf{x}}_k))^2$$

Assim,

$$\hat{R}(g) = \frac{1}{m} \sum_{k=1}^{m} W_k$$

Interpretação

Se as observações do conjunto de teste são i.i.d., então $W_1, \ldots, W_m$ são variáveis aleatórias **independentes e identicamente distribuídas**.
Logo, $\hat{R}(g)$ é simplesmente **a média dessas variáveis**.

Aproximação normal

Pelo **Teorema Central do Limite**,

$$\hat{R}(g) \approx \mathcal{N}\left(R(g), \frac{1}{m}\operatorname{Var}(W_1)\right)$$

quando m é grande.

Intervalo de confiança para o risco

Na prática, estimamos $\operatorname{Var}(W_1)$ pela variância amostral:

$$\hat{\sigma}^2 = \frac{1}{m-1}\sum_{k=1}^{m}(W_k - \bar{W})^2$$

onde

$$\bar{W} = \hat{R}(g)$$

Um intervalo de confiança aproximado de 95% é

$$\hat{R}(g) \pm 1.96 \frac{\hat{\sigma}}{\sqrt{m}}$$

Interpretação prática

O intervalo de confiança fornece uma **medida de incerteza** da estimativa do risco. Isso permite avaliar:

- se o erro estimado é confiável
- se dois modelos possuem desempenho estatisticamente diferente

Um insight importante

A largura do intervalo de confiança é aproximadamente

$$4\sqrt{\frac{1}{m}\hat{\sigma}^2}$$

Portanto, quanto **maior o conjunto de teste**, menor a incerteza da estimativa do risco.

Escolhendo o tamanho da divisão

Podemos escolher o tamanho do conjunto de teste m de modo que a largura do intervalo de confiança seja menor que uma tolerância desejada ε.
Ou seja, queremos

$$4\sqrt{\frac{\hat{\sigma}^2}{m}} \leq \varepsilon$$

Resolvendo para m, obtemos

$$m \geq \frac{16\hat{\sigma}^2}{\varepsilon^2}$$

Interpretação

Esse resultado mostra que:

- quanto **menor a precisão desejada** (ε grande), menor pode ser o conjunto de teste;
- quanto **maior a variabilidade do erro**, maior deve ser o conjunto de teste;
- o erro estimado fica mais preciso à medida que m **aumenta**.

Consequência prática em Machine Learning

Treinar um bom modelo exige muitos dados, pois precisamos aprender a função de predição g.

Por outro lado, **estimar o erro do modelo exige relativamente menos dados**.

Isso explica por que, na prática, usamos divisões como:

- **70% / 30%**
- **80% / 20%**
- **90% / 10%**

entre **treinamento** e **teste**.

Exemplo: Seleção de modelo

Retomamos o exemplo **Expectativa de vida vs PIB per capita**.

Nosso objetivo agora é escolher o **melhor modelo de regressão** dentro da classe

$$G = \left\{ g(x) : \; g(x) = \beta_0 + \sum_{i=1}^{p} \beta_i x^i, \quad p \in \{1, 2, \dots, 50\} \right\}$$

Ou seja, consideramos **regressões polinomiais de diferentes graus**.

Ideia do experimento

Para cada valor de p:

1. Ajustamos o modelo usando o **conjunto de treinamento**
2. Calculamos o **erro quadrático médio (EQM)** no treinamento
3. Calculamos o **erro no conjunto de validação**

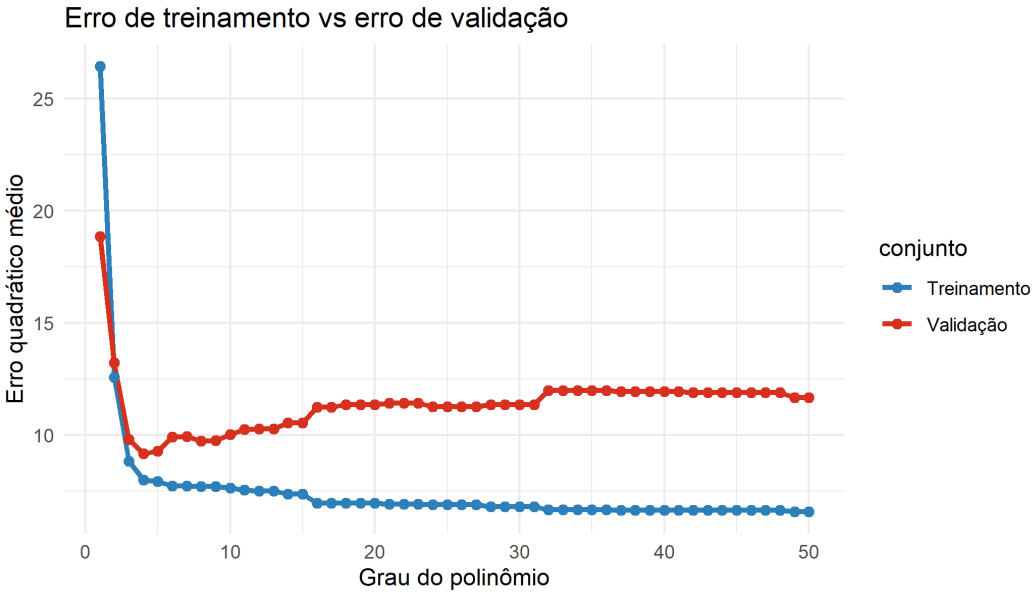
Erro de treinamento vs erro de validação
Erro quadrático médio
25
20
15
10
0
10
20
30
40
50
Grau do polinômio
conjunto
Treinamento
Validação

O que acontece no treinamento?

À medida que aumentamos o número de parâmetros p:

- o modelo se torna **mais flexível**
- o **erro de treinamento sempre diminui**

Isso ocorre porque modelos mais complexos conseguem **ajustar melhor os dados observados**.

Problema: super-ajuste

Minimizar o erro no conjunto de treinamento **não garante** bom desempenho em novos dados.

Quando p é muito grande, ocorre **super-ajuste (overfitting)**.

O modelo passa a capturar **ruído do conjunto de treinamento**.

Papel do conjunto de validação

O conjunto de validação fornece uma estimativa do erro de generalização. Observamos que:

- o erro de treinamento continua diminuindo
- o erro de validação **primeiro diminui e depois aumenta**

Escolha do modelo

O modelo ideal é aquele que **minimiza o erro no conjunto de validação**.
Esse modelo fornece o melhor compromisso entre:

- **flexibilidade**
- **capacidade de generalização**.

Conclusão

Minimizar o erro no conjunto de validação leva a um modelo mais adequado para prever **novas observações**.
Esse procedimento é conhecido como **data splitting para seleção de modelos**.

Penalização: uma alternativa

Uma forma alternativa de estimar o risco de um modelo g é usar uma **medida de penalização ou complexidade**.

A ideia é que modelos muito complexos tendem a **subestimar o risco verdadeiro** quando avaliados apenas pelo erro no conjunto de treinamento.

Problema

O erro quadrático médio observado, $EQM(g)$, tende a **subestimar o risco verdadeiro** $R(g)$.
Essa diferença aumenta quando o modelo possui **muitos parâmetros**.

Ideia da penalização

A solução é adicionar uma penalização que mede a complexidade do modelo.
Assim, usamos um critério da forma

$$R(g) \approx EQM(g) + P(g),$$

onde $P(g)$ é uma função de penalização.

Medidas de penalização

Uma escolha simples para $P(g)$ é usar o **número de parâmetros do modelo**.
Dois critérios muito utilizados são:

- AIC

$$P(g) = \frac{2}{np\hat{\sigma}^2}$$

- BIC

$$P(g) = \frac{\log(n)}{np\hat{\sigma}^2}$$

onde

- p é o número de parâmetros
- $\hat{\sigma}^2$ estima $\mathrm{Var}(Y|\mathbf{x})$.

Interpretação

Esses critérios equilibram:

- **qualidade do ajuste**
- **complexidade do modelo**

Modelos com muitos parâmetros recebem **penalizações maiores**. A penalização é uma forma de evitar **overfitting**.

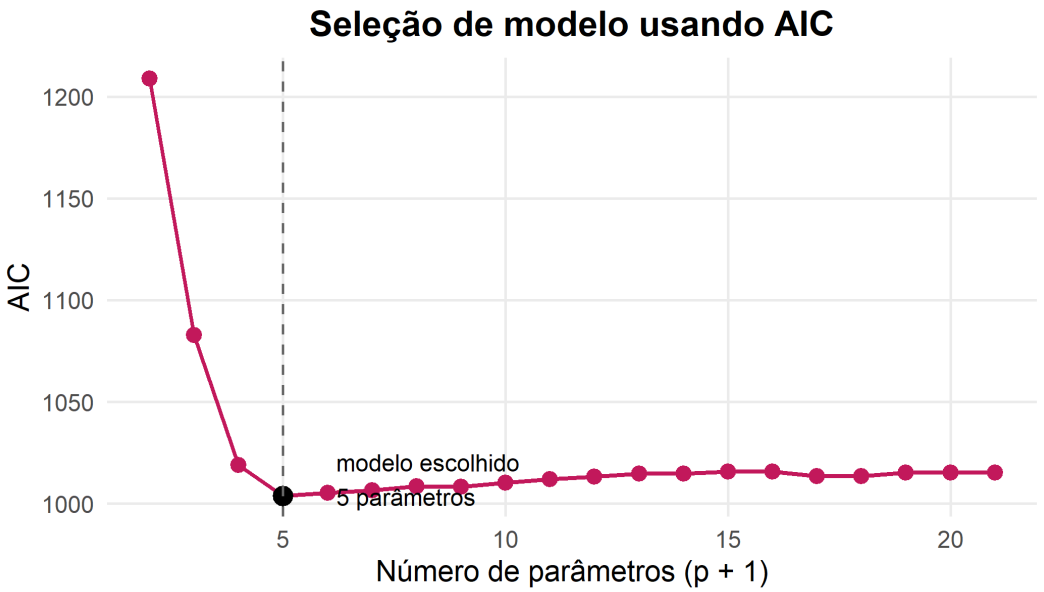
Seleção de modelo usando AIC
AIC
1200
1150
1100
1050
1000
modelo escolhido
5 parâmetros
5
10
15
20
Número de parâmetros (p + 1)

Balanço entre Viés e Variância

Decomposição do erro quadrático

Uma grande vantagem do **erro quadrático** é que ele possui uma decomposição muito interpretável.
Para um novo ponto $\mathbf{x}$, o erro esperado pode ser escrito como

$$\mathbb{E}\left[(Y - \hat{g}(\mathbf{x}))^2 \mid X = \mathbf{x}\right] = \mathrm{Var}(Y \mid X = \mathbf{x}) + \left(r(\mathbf{x}) - \mathbb{E}[\hat{g}(\mathbf{x})]\right)^2 + \mathrm{Var}(\hat{g}(\mathbf{x}))$$

Significado das quantidades

- $r(\mathbf{x}) = \mathbb{E}[Y \mid X = \mathbf{x}]$ é a **função de regressão verdadeira**.
- $\hat{g}(\mathbf{x})$ é o **estimador aprendido a partir dos dados**.
- A aleatoriedade vem de duas fontes:
  - o ruído em Y
  - a amostra de treinamento usada para construir $\hat{g}$.

Decomposição do erro

O erro esperado pode ser decomposto em três termos:

1. **Ruído irreducível**

$$\mathrm{Var}(Y \mid X = \mathbf{x})$$

2. **Viés ao quadrado**

$$\left(r(\mathbf{x}) - \mathbb{E}[\hat{g}(\mathbf{x})]\right)^2$$

3. **Variância do estimador**

$$\mathrm{Var}(\hat{g}(\mathbf{x}))$$

Interpretação

- O **ruído irreducível** depende apenas da distribuição dos dados e **não pode ser reduzido**.
- O **viés** mede o erro sistemático do modelo.
- A **variância** mede o quanto o modelo muda quando o conjunto de treinamento muda.

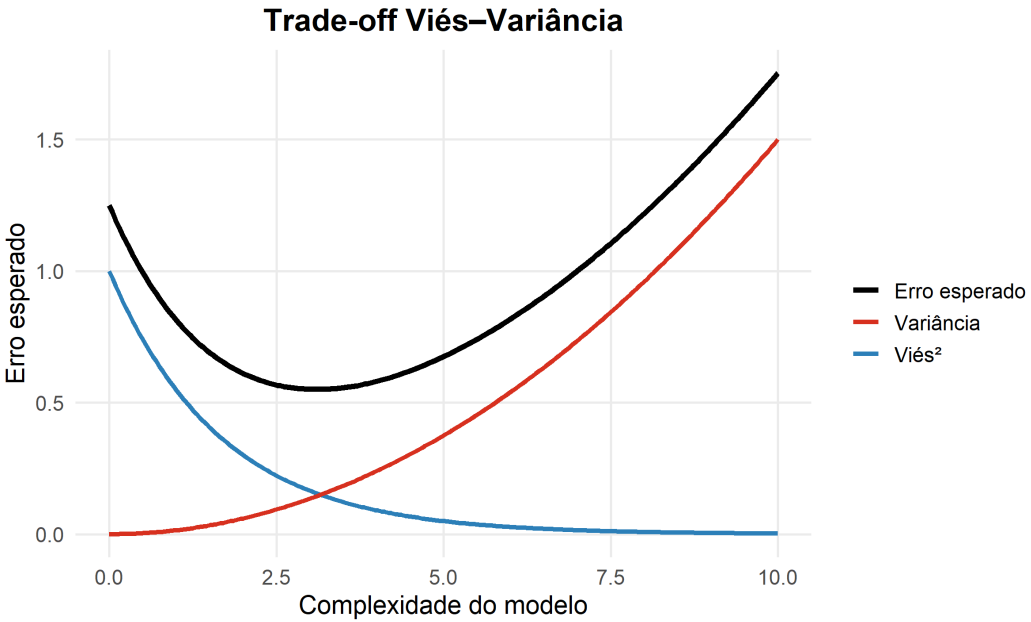
Trade-off Viés–Variância
Erro esperado
1.5
1.0
0.5
0.0
0.0
2.5
5.0
7.5
10.0
Complexidade do modelo
Erro esperado
Variância
Viés²

Trade-off viés–variância

À medida que a complexidade do modelo aumenta:

- o **viés diminui**
- a **variância aumenta**

O **erro esperado** é a soma de:

- viés^2
- variância
- ruído irreducível

Assim,

- modelos simples $\rightarrow$ alto viés, baixa variância
- modelos complexos $\rightarrow$ baixo viés, alta variância

O melhor modelo equilibra viés e variância

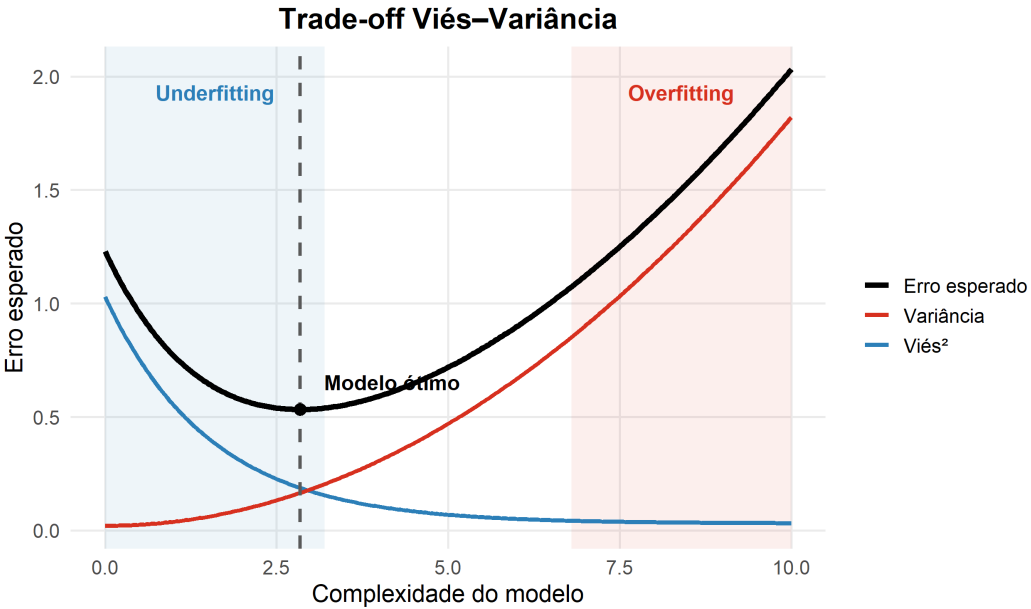
Trade-off Viés–Variância
Underfitting
Overfitting
Modelo ótimo
Erro esperado
Complexidade do modelo
0.0
0.5
1.0
1.5
2.0
0.0
2.5
5.0
7.5
10.0
Erro esperado
Variância
Viés²

Parâmetros de sintonia (Tuning Parameters)

No exemplo anterior usamos regressões polinomiais

$$g(x) = \beta_0 + \sum_{i=1}^{p} \beta_i x^i$$

O parâmetro p (grau do polinômio) controla a **complexidade do modelo**.

Papel do parâmetro p

O valor de p controla o equilíbrio entre:

- **viés**
- **variância**
- valores pequenos de $p \rightarrow$ modelo simples $\rightarrow$ **alto viés**
- valores grandes de $p \rightarrow$ modelo flexível $\rightarrow$ **alta variância**

Escolhendo o valor de p

O valor ótimo de p depende de:

- o tamanho da amostra n
- a forma da função verdadeira

$$r(x) = \mathbb{E}[Y|X = x]$$

Tuning parameter

O parâmetro p é chamado de **tuning parameter**.

- controla a **complexidade do modelo**
- não é estimado diretamente pelos dados
- precisa ser **escolhido usando um critério de validação**

Como escolher tuning parameters

Na prática, escolhemos esses parâmetros usando:

- **data splitting**
- **validação cruzada (cross-validation)**

O objetivo é selecionar o valor que **minimiza o erro de predição em novos dados**.

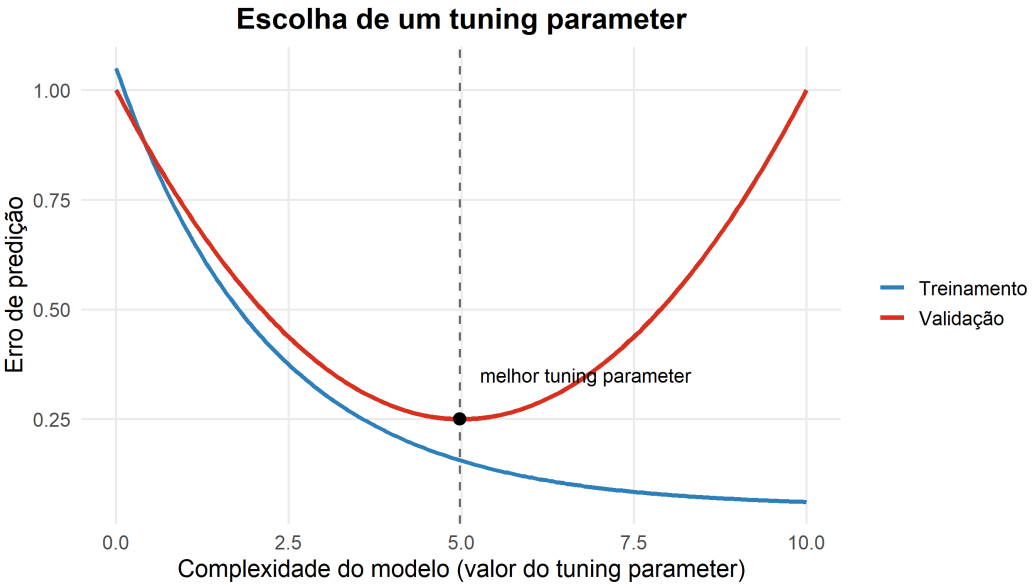
Escolha de um tuning parameter
1.00
0.75
0.50
0.25
Erro de predição
melhor tuning parameter
0.0
2.5
5.0
7.5
10.0
Complexidade do modelo (valor do tuning parameter)
Treinamento
Validação

References

Breiman, Leo. 2001. "Statistical Modeling: The Two Cultures." *Statistical Science* 16 (3): 199–231. https://doi.org/10.1214/ss/1009213726.

Tenenbaum, Joshua B., Vin de Silva, and John C. Langford. 2000. "A Global Geometric Framework for Nonlinear Dimensionality Reduction." *Science* 290 (5500): 2319–23. https://doi.org/10.1126/science.290.5500.2319.