Parte 1 : Regressão

Introdução

O que é Aprendizagem?

- **Definição de aprendizagem:** É uma mudança adaptativa no comportamento causada pela experiência.

O que é Aprendizagem?

- **Definição de aprendizagem:** É uma mudança adaptativa no comportamento causada pela experiência.
- Praticamente todos os animais com sistema nervoso central são capazes de aprender (mesmo os mais simples).

O que é Aprendizagem?

- **O que significa para um computador aprender? Por que queremos que ele aprenda? Como fazemos para que ele aprenda?**
  - Queremos que computadores aprendam quando é muito difícil ou muito caro programá-los diretamente para executar uma tarefa.
  - Fazemos o computador "programar a si mesmo" ao mostrar exemplos de entradas e saídas.
    - Na prática, escrevemos um programa "parametrizado" e deixamos que o algoritmo de aprendizagem encontre o conjunto de parâmetros que melhor aproxima a função ou o comportamento desejado.

Definições Clássicas de Aprendizado de Máquina

Arthur Samuel (1959):

"Aprendizado de Máquina é o campo de estudo que dá aos computadores a habilidade de aprender sem serem explicitamente programados."

Definições Clássicas de Aprendizado de Máquina

Arthur Samuel (1959):

"Aprendizado de Máquina é o campo de estudo que dá aos computadores a habilidade de aprender sem serem explicitamente programados."

Tom Mitchell (1997):

"Dizemos que um programa de computador aprende a partir de uma experiência E, com respeito a alguma tarefa T e alguma medida de desempenho P, se o seu desempenho na tarefa T, medido por P, melhora com a experiência E."

Definições Clássicas de Aprendizado de Máquina

- T — **Task (Tarefa):** A tarefa que queremos resolver.
  - Exemplos:
    - classificar e-mails, prever preço de casas, detectar fraude

Definições Clássicas de Aprendizado de Máquina

- T — **Task (Tarefa):** A tarefa que queremos resolver.
  - Exemplos:
    - classificar e-mails, prever preço de casas, detectar fraude
- E — **Experience (Experiência):** Os dados utilizados para aprender.
  - Exemplo:
    - histórico de e-mails rotulados como **spam** ou **não spam**

Definições Clássicas de Aprendizado de Máquina

- T — **Task (Tarefa):** A tarefa que queremos resolver.
  - Exemplos:
    - classificar e-mails, prever preço de casas, detectar fraude
- E — **Experience (Experiência):** Os dados utilizados para aprender.
  - Exemplo:
    - histórico de e-mails rotulados como **spam** ou **não spam**
- P — **Performance (Desempenho):** Métrica usada para avaliar o modelo.
  - Exemplos:
    - acurácia, erro quadrático médio, AUC

Por que precisamos de Aprendizado de Máquina?

É muito difícil resolver problemas como o **reconhecimento de objetos bidimensionais ou tridimensionais**.

- Não sabemos qual programa escrever, pois **não sabemos exatamente como o cérebro realiza essa tarefa**.
- Mesmo que soubéssemos, **o programa provavelmente seria extremamente complexo**.

Exemplo: reconhecimento de dígitos manuscritos

Um exemplo clássico é o reconhecimento automático de **dígitos escritos à mão**.

A variabilidade na forma como cada pessoa escreve os números torna muito difícil criar **regras explícitas de programação** para identificar cada dígito.

Em vez disso, usamos **aprendizado de máquina**, que permite ao algoritmo **aprender padrões diretamente a partir dos dados**.

Exemplo: dígitos manuscritos (MNIST)

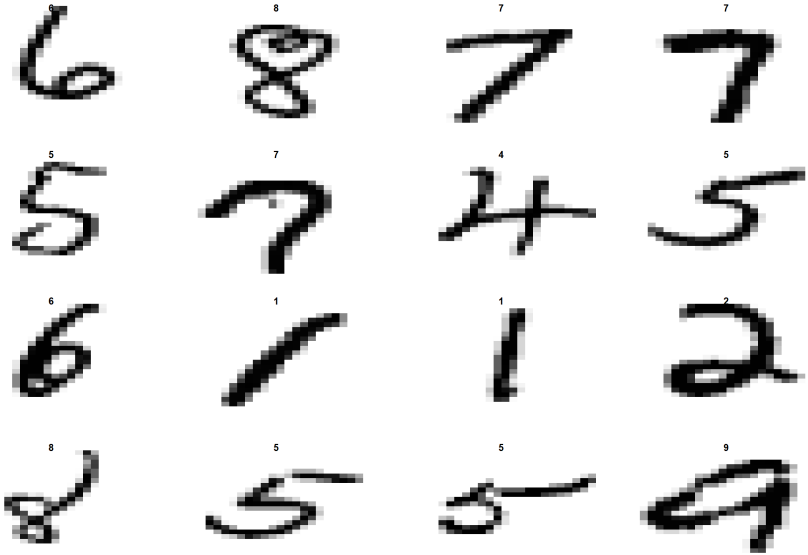

Por que precisamos de Aprendizado de Máquina?

A abordagem de aprendizado de máquina

Em vez de escrever um programa manualmente, coletamos **muitos exemplos** que especificam a saída correta para uma determinada entrada.
Um **algoritmo de aprendizado de máquina** produz um programa a partir desses dados.

- O programa produzido por um algoritmo de aprendizado pode ser **muito diferente de um programa típico escrito manualmente**.
- Se fizermos isso corretamente, o programa **funciona para novos casos**, além daqueles usados no treinamento.

Observação importante

Grandes quantidades de computação e dados hoje são mais baratas do que pagar alguém para escrever um programa manualmente.

Programação Tradicional vs Aprendizado de Máquina

Programação tradicional

Nós escrevemos explicitamente as regras.

Entrada + Regras $\rightarrow$ Saída

Exemplo:

- **Entrada:** dados de um cliente
- **Regras:** lógica escrita pelo programador
- **Saída:** decisão do sistema

Aprendizado de máquina

O algoritmo aprende as regras a partir dos dados.
Entrada + Saída $\rightarrow$ Algoritmo $\rightarrow$ Modelo
Exemplo:

- **Dados:** histórico de clientes
- **Respostas:** compra / não compra
- **Modelo aprendido:** sistema de previsão

Diferentes Tipos de Aprendizado

Aprendizado Supervisionado

Entrada $\rightarrow$ Saída conhecida

Exemplos:

- classificação de imagens
- previsão de preços
- detecção de spam

Aprendizado Não Supervisionado

Somente entradas disponíveis

Objetivo:

- descobrir padrões ocultos
- identificar grupos

Exemplos:

- **clusterização**
- **redução de dimensionalidade**

Aprendizado por Reforço

Agente interage com um ambiente

Componentes:

- **estado**
- **ação**
- **recompensa**

Exemplos:

- robôs
- jogos
- veículos autônomos

Supervisionado

↓

Classificação
Regressão

Não Supervisionado

↓

Clusterização
Redução de Dimensão

Reforço

↓

Aprendizado de Políticas

Aprendizado Supervisionado

Notação e Suposições

No **aprendizado supervisionado**, dispomos de um conjunto de treinamento:

$$\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$$

onde:

- $x_i = (x_{i1}, \dots, x_{id})$ representa as **variáveis explicativas**
- y_i representa a **variável resposta observada**

A partir dos dados de treinamento, queremos aprender uma função $f(\mathbf{x})$ capaz de prever a resposta para **novas observações**.

A partir dos dados de treinamento, queremos aprender uma função $f(\mathbf{x})$ capaz de prever a resposta para **novas observações**.

Quando Y é **quantitativa**, buscamos aproximar a **função de regressão**

$$f(\mathbf{x}) = \mathbb{E}[Y \mid X = \mathbf{x}]$$

como forma de descrever a relação entre uma variável aleatória $Y \in \mathbb{R}$ e um vetor de variáveis explicativas $\mathbf{x} = (x_1, \dots, x_p) \in \mathbb{R}^p$

Formulação do aprendizado estatístico

Uma forma comum de representar o problema é

$$Y = f(\mathbf{x}) + \varepsilon$$

onde:

- $f(\mathbf{x})$ é a **função verdadeira desconhecida**
- ε representa **ruído aleatório**

O objetivo do **aprendizado supervisionado** é **estimar** (treinar) uma aproximação

$$\hat{f}(\mathbf{x}) \approx f(\mathbf{x})$$

Predição versus Inferência: Por que estimar f(x)?

Exemplo 1.1 — Expectativa de vida e PIB per capita

Considere dados de **211 países no ano de 2012**, contendo:

- **PIB per capita**
- **expectativa de vida**

Uma pergunta natural é:

> *Como podemos usar esses dados para **estabelecer uma relação entre essas duas variáveis**?*

Objetivo

Queremos usar os dados para **estimar a expectativa de vida de um país** quando seu **PIB per capita é conhecido**.
Formalmente, queremos estimar

$$\mathbb{E}[Y \mid X = x]$$

onde

- $Y =$ expectativa de vida de um país
- $X =$ PIB per capita

Interpretação da função de regressão

A quantidade

$$\mathbb{E}[Y \mid X = x]$$

representa a **expectativa de vida média esperada para países com PIB per capita igual a** x.

Estimando essa função podemos:

- **prever expectativa de vida** a partir do PIB per capita
- **investigar a relação entre as variáveis**
- **testar a hipótese de que não existe relação entre elas**

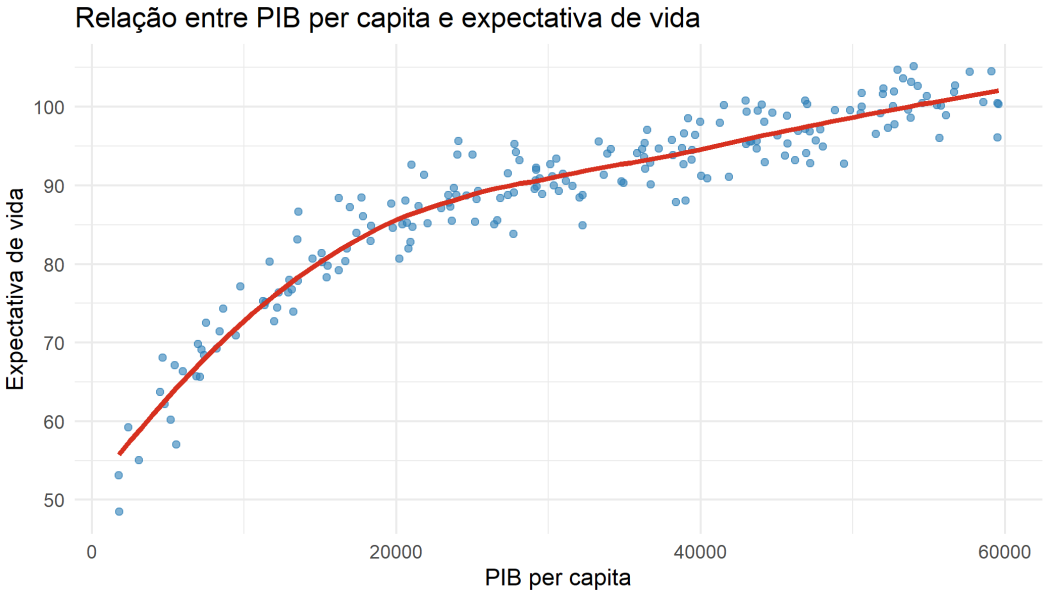
Relação entre PIB per capita e expectativa de vida
Expectativa de vida
100
90
80
70
60
50
0
20000
40000
60000
PIB per capita

Predição versus Inferência: Por que estimar f(x)?

Exemplo 1.2 — Distância de uma galáxia até a Terra

Na cosmologia, uma variável extremamente importante é o **desvio para o vermelho** (*redshift*) de uma galáxia.
Esse valor mede **quão distante a galáxia está da Terra**.

O problema

O **redshift** pode ser medido com grande precisão por meio de **espectroscopia**.
No entanto:

- esse procedimento é **caro**
- exige **muito tempo de observação**

Por isso, surge a seguinte pergunta:

*Podemos estimar o **redshift** utilizando apenas **imagens das galáxias**?*

Formulação como aprendizado supervisionado

Considere uma amostra de treinamento

$$(\mathbf{x}_1, Y_1), \ldots, (\mathbf{x}_n, Y_n)$$

onde

- $\mathbf{x}_i$ = imagem da i-ésima galáxia
- Y_i = redshift medido por espectroscopia

Objetivo

Queremos estimar a **função de regressão**

$$f(x) = \mathbb{E}[Y \mid X = \mathbf{x}]$$

A partir dessa função podemos:

- prever o **redshift** de novas galáxias
- estimar suas **distâncias até a Terra**

Predição versus Inferência: Por que estimar f(x)?

Exemplo 1.3 — Isomap Face Data

Neste conjunto de dados, proveniente de Tenenbaum, Silva, and Langford (2000), o objetivo é estimar **a direção para a qual uma pessoa está olhando**.

- **Resposta (Y):** direção do olhar
- **Covariáveis ($\mathbf{x}$):** imagem da face da pessoa

Formulação do problema

Uma forma de resolver esse problema é estimar a **função de regressão**

$$f(x) = \mathbb{E}[Y \mid X = \mathbf{x}]$$

utilizando uma amostra de treinamento

$$(\mathbf{x}_1, Y_1), \ldots, (\mathbf{x}_n, Y_n)$$

onde:

- $\mathbf{x}_i$ = imagem da face do indivíduo
- Y_i = direção do olhar

Predição em novas imagens

Depois de estimar a função $f(\mathbf{x})$, podemos utilizá-la para

- prever a **direção do olhar** em novas imagens
- inferir a variável resposta Y a partir das covariáveis $\mathbf{x}$

Em outras palavras:
imagem da face $\rightarrow$ modelo $\rightarrow$ direção do olhar

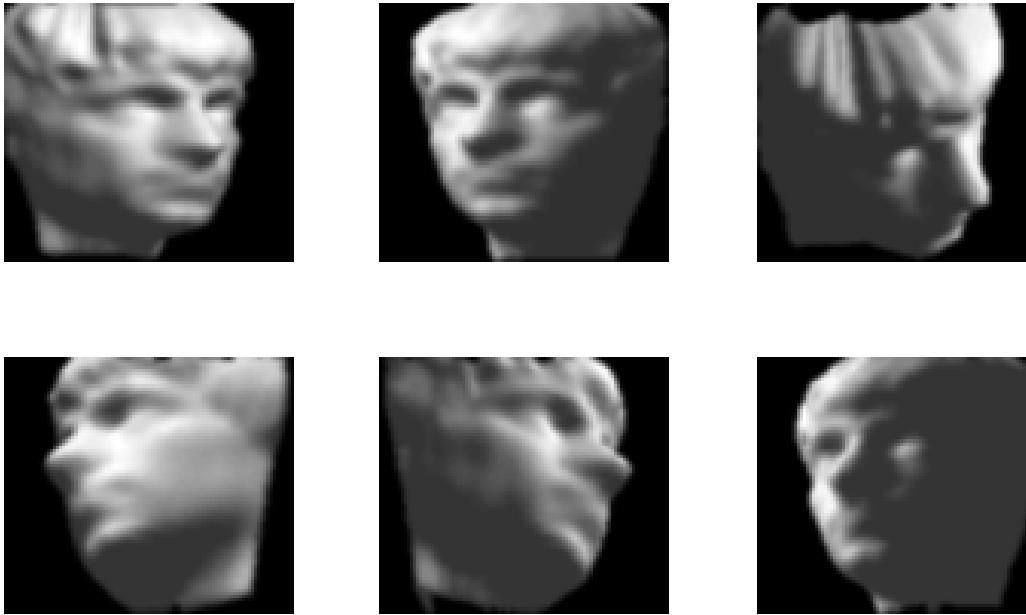

Predição versus Inferência: Por que estimar f(x)?

Exemplo 1.4 — Predição do ano de lançamento de músicas

Os dados do **YearPredictionMSD** contêm diversas covariáveis sobre músicas do banco **Million Song Dataset**.

Alguns exemplos de variáveis:

- características de **timbre**
- **energia** da música
- **dançabilidade**
- outras características acústicas

Além disso, o conjunto de dados contém o **ano de lançamento** de cada música.

Formulação como problema de regressão

Considere

- $\mathbf{x}$ = vetor de características da música
- Y = ano de lançamento

Queremos estimar a **função de regressão**

$$f(x) = \mathbb{E}[Y \mid X = x]$$

ou seja, o **ano esperado de lançamento dado o conjunto de características da música**.

O que podemos fazer com esse modelo?

Uma estimativa de $f(x)$ pode ser usada para:

1. **Predição**

Prever o ano de lançamento de novas músicas a partir de suas características

2. **Interpretação**

Investigar quais características musicais estão associadas ao ano de lançamento

MÚSICAS DOS ANOS 70 ERAM MAIS DANÇÁVEIS?
MÚSICAS RECENTES POSSUEM MAIOR ENERGIA?
QUANTOS TIPOS DE MÚSICA EXISTEM NO MUNDO?

Interpretação em aprendizado supervisionado

Temos uma amostra de treinamento

$$(\mathbf{x}_1, Y_1), \dots, (\mathbf{x}_n, Y_n)$$

onde:

- $\mathbf{x}_i$ = características da música
- Y_i = ano de lançamento

O objetivo é aprender uma função

$$\hat{f}(x)$$

capaz de prever o **ano de lançamento de novas músicas**.

Dois objetivos do aprendizado supervisionado

De modo geral, os problemas apresentados podem ser divididos em **dois objetivos principais**.

Objetivo inferencial

Perguntas típicas:

- Quais **preditores** são importantes?
- Qual é a **relação entre cada preditor e a variável resposta**?
- Qual é o **efeito de mudar o valor de um preditor** na variável resposta?

Esse tipo de análise busca **interpretar a relação entre as variáveis**.

Objetivo preditivo

Queremos construir uma função

$$g : \mathbb{R}^d \to \mathbb{R}$$

com **bom poder preditivo**.
A ideia é encontrar uma função g tal que, para novas observações i.i.d.

$$(X_{n+1}, Y_{n+1}), \dots, (X_{n+m}, Y_{n+m}),$$

tenhamos boas aproximações

$$g(x_{n+1}) \approx y_{n+1}, \dots, g(x_{n+m}) \approx y_{n+m}$$

Duas culturas em modelagem estatística

Breiman (2001) argumenta que existem duas culturas no uso de modelos estatísticos (em especial modelos de regressão).

Data Modeling Culture

- Domina a **comunidade estatística**.
- O principal objetivo está na **interpretação dos parâmetros**.
- **Testar suposições do modelo** é fundamental.

Foco:

- **Inferência**
- Compreensão do mecanismo gerador dos dados

Algorithmic Modeling Culture

- Domina a **comunidade de Machine Learning**.
- O foco está em **obter bons algoritmos preditivos**.
- Os resultados podem ser interpretados, mas **isso geralmente não é o foco principal**.

Foco:

- **Predição**
- Desempenho em novos dados

Integração entre Estatística e Machine Learning

Machine Learning e Estatística não são opostos: são complementares.

Historicamente, as duas áreas enfatizaram objetivos diferentes:

- **Estatística:** foco em **inferência e interpretação** dos modelos.
- **Machine Learning:** foco em **predição e desempenho em novos dados**.

Tendência atual

Hoje muitos métodos modernos procuram **combinar as duas culturas**, buscando:

- **alto desempenho preditivo**
- **interpretação dos modelos**

Exemplos:

- **Random Forest interpretável**
- **SHAP (Shapley Additive Explanations)**
- **modelos semiparamétricos:** GAM (Modelos aditivos generalizados), Modelo de Cox (riscos proporcionais), etc.

Regressão linear

modelo paramétrico
simples e interpretável
baixa flexibilidade

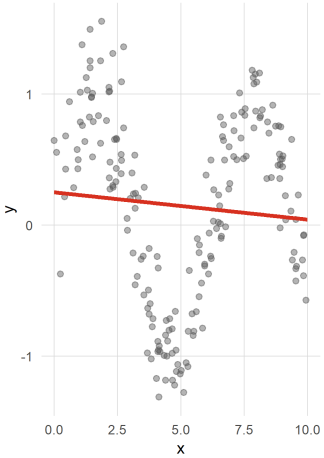

GAM

modelo semiparamétrico
mantém interpretabilidade
permite relações não lineares

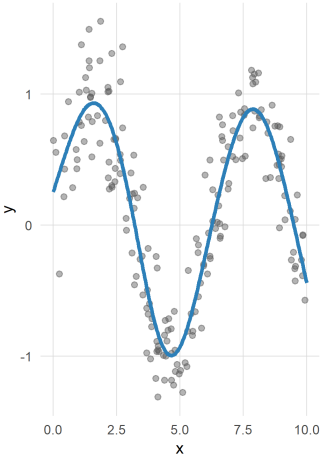

Árvore de decisão

modelo algorítmico
muito flexível
foco em predição

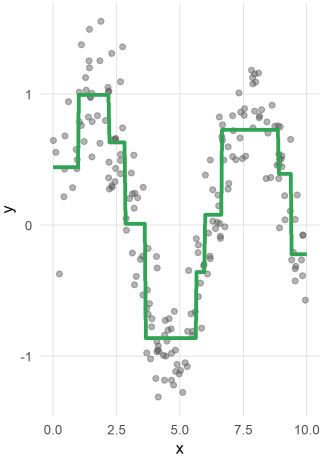

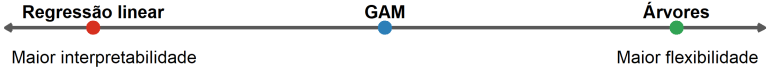

References

Breiman, Leo. 2001. "Statistical Modeling: The Two Cultures." *Statistical Science* 16 (3): 199–231. https://doi.org/10.1214/ss/1009213726.

Tenenbaum, Joshua B., Vin de Silva, and John C. Langford. 2000. "A Global Geometric Framework for Nonlinear Dimensionality Reduction." *Science* 290 (5500): 2319–23. https://doi.org/10.1126/science.290.5500.2319.