

Parte 1 : Regressão

Métodos Paramétricos

Métodos paramétricos

Métodos **paramétricos** assumem que a função de regressão pode ser descrita por um **número finito de parâmetros**.

Aqui, iremos nos concentrar em **modelos de regressão linear**.

- ▶ Grande parte do conteúdo pode parecer familiar;
- ▶ porém, será apresentado sob a perspectiva de **modelagem preditiva e seleção de modelos**.

Regressão linear

Na regressão linear, a função de predição possui **forma linear nos parâmetros**.

A função de predição pode ser escrita como

$$g(\mathbf{x}) = \beta^t \mathbf{x}$$

ou explicitamente

$$g(\mathbf{x}) = \beta_0 x_0 + \beta_1 x_1 + \cdots + \beta_p x_p$$

Adotamos a convenção $x_0 = 1$. Assim, β_0 corresponde ao **intercepto do modelo**.

O vetor de parâmetros é

$$\beta^t = (\beta_0, \beta_1, \dots, \beta_p)$$

Transformações de variáveis

Os termos x_i **não precisam ser apenas as variáveis originais**. Podemos construir **novas covariáveis** a partir delas, por exemplo:

- ▶ termos quadráticos: X_i^2
- ▶ interações: $X_i X_j$
- ▶ transformações não lineares

Isso permite que **modelos lineares representem relações não lineares nos dados**.

O Método dos Mínimos Quadrados

Uma forma de estimar os coeficientes β da regressão linear é utilizar o **método dos mínimos quadrados**.

A ideia é escolher os coeficientes que **minimizam a soma dos erros quadráticos**:

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_{i1} - \dots - \beta_d x_{ip})^2$$

Interpretação

O método escolhe os parâmetros que **minimizam a soma dos quadrados dos resíduos**:

$$\text{resíduo}_i = Y_i - g(X_i)$$

Logo, o objetivo é minimizar

$$\sum_{i=1}^n (Y_i - g(X_i))^2$$

Geometricamente, isso corresponde a **ajustar o hiperplano que fica mais próximo possível dos dados**.

Forma matricial do modelo

O modelo de regressão pode ser escrito em forma matricial como

$$y = X\beta + \varepsilon$$

onde

- ▶ y é o vetor de respostas
- ▶ X é a **matriz de covariáveis**
- ▶ β é o vetor de parâmetros

Solução dos mínimos quadrados

A solução analítica do problema é dada por

$$\hat{\beta} = (X^t X)^{-1} X^t y$$

Essa expressão é conhecida como a **equação normal** da regressão linear.

Estrutura da matriz de dados

A matriz de covariáveis possui a forma

$$X = \begin{pmatrix} x_{1,0} & x_{1,1} & \cdots & x_{1,p} \\ x_{2,0} & x_{2,1} & \cdots & x_{2,p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n,0} & x_{n,1} & \cdots & x_{n,p} \end{pmatrix}$$

e o vetor resposta é

$$y = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}$$

Adotamos a convenção $x_{i,0} = 1$ para representar o **intercepto** do modelo.

Função de regressão estimada

Uma vez estimados os coeficientes pelo método dos mínimos quadrados, a **função de predição** é dada por

$$g(\mathbf{x}) = \hat{\beta}^t \mathbf{x}$$

Assim, para um novo vetor de covariáveis $\mathbf{x}$, a previsão é

$$\hat{y} = g(\mathbf{x})$$

Justificativa estatística do método

Quando a suposição de linearidade falha

A suposição de que a verdadeira função de regressão

$$r(\mathbf{x}) = E[y \mid X = \mathbf{x}]$$

é **linear** muitas vezes **não é válida na prática**.

Mesmo assim, modelos lineares frequentemente apresentam **bom desempenho preditivo**.

Ideia central

Mesmo quando $r(\mathbf{x})$ não é linear, frequentemente existe um vetor β_* tal que o preditor linear

$$g_{\beta_*}(\mathbf{x}) = \beta_*^t \mathbf{x}$$

possui **bom poder preditivo**.

O melhor preditor linear

O vetor β_* é definido como aquele que **minimiza o risco quadrático**:

$$\beta_* = \arg \min_{\beta} R(g_{\beta}) = \arg \min_{\beta} E[(y - \beta^t \mathbf{x})^2]$$

Esse vetor define a **melhor aproximação linear** da relação entre $\mathbf{x}$ e y .

β_* é chamado de **oráculo**.

Interpretação

Mesmo quando o verdadeiro modelo $r(x)$ não é linear, o método dos mínimos quadrados estima o **melhor preditor linear possível**.

Ou seja, ele encontra a função linear que **minimiza o erro quadrático médio esperado**.

Consequência importante

Quando o tamanho da amostra cresce,

$$\hat{\beta} \rightarrow \beta_*$$

Ou seja, o estimador obtido pelos **mínimos quadrados converge para o melhor preditor linear**, mesmo que o modelo esteja **mal especificado**.

Mínimos quadrados não precisa que o modelo seja verdadeiro.

Ele encontra a melhor aproximação linear da realidade.

Limitações do método dos mínimos quadrados

Quando o número de covariáveis é **muito grande**, o método dos mínimos quadrados pode apresentar **desempenho ruim**.

Isso ocorre principalmente por dois motivos:

- ▶ **super-ajuste (overfitting)**
- ▶ **alta variância do estimador**

Problema em alta dimensão

Considere:

- ▶ p = número de covariáveis
- ▶ n = tamanho da amostra

Quando $p > n$ o estimador de mínimos quadrados **não está bem definido**.

Por quê?

A solução dos mínimos quadrados é

$$\hat{\beta} = (X^t X)^{-1} X^t y$$

Porém, quando $p > n$, $X^t X$ **não é invertível**.

Logo, o estimador não pode ser calculado diretamente.

Consequência


Em problemas com **muitas variáveis** (alta dimensão):

- ▶ o método clássico de mínimos quadrados **não funciona bem**
- ▶ precisamos utilizar **métodos alternativos**

Por exemplo:

- ▶ **regularização (Ridge, Lasso)**
- ▶ **redução de dimensionalidade**
- ▶ **seleção de variáveis**

Quando $p > n$: infinitos modelos ajustam perfeitamente os dados



Interpretação

Quando temos mais parâmetros do que observações, o modelo tem liberdade suficiente para passar exatamente por todos os pontos.

O problema é que existem infinitas funções que fazem isso, e elas podem ser completamente diferentes fora da amostra.

References

- Morettin, Pedro A., and Julio M. Singer. 2019. *Estatística e Ciência de Dados*. Rio de Janeiro: LTC.
- Neter, John, Michael H. Kutner, Christopher J. Nachtsheim, and William Wasserman. 1996. *Applied Linear Statistical Models*. 4th ed. Chicago: Irwin.