

Parte 1 : Regressão

Métodos Paramétricos em Altas Dimensões

Busca pelo melhor subconjunto de covariáveis

Quando o número de covariáveis é grande, uma estratégia natural é **remover algumas variáveis do modelo**.

O objetivo é **reduzir a variância da função de predição estimada**.

Ideia central

Ao retirar algumas covariáveis do modelo:

- ▶ a **variância do estimador diminui**
- ▶ mas o **viés pode aumentar**

Esse é mais um exemplo do **trade-off viés–variância**.

Quando isso funciona bem?

Se algumas covariáveis possuem **pouca ou nenhuma relação com a resposta y** , então removê-las:

- ▶ aumenta **pouco o viés**
- ▶ reduz **consideravelmente a variância**

Como consequência, o **poder preditivo do modelo pode aumentar**.

Estratégia

A solução consiste em encontrar um **subconjunto de covariáveis**

$$S \subset \{1, 2, \dots, p\}$$

que produza o **melhor desempenho preditivo**.

Formulação do problema

Podemos escrever o problema como

$$\hat{\beta}_{L_0} = \arg \min_{\beta_0 \in \mathbb{R}, \beta \in \mathbb{R}^p} \sum_{k=1}^n \left(y_k - \beta_0 - \sum_{i=1}^p \beta_i x_{k,i} \right)^2 + \lambda \sum_{i=1}^p I(\beta_i \neq 0)$$

Interpretação da expressão

A função objetivo possui **duas partes**:

1 Erro de ajuste

$$\sum_{k=1}^n \left(y_k - \beta_0 - \sum_{i=1}^p \beta_i x_{k,i} \right)^2$$

mede o **erro quadrático de treinamento**.

2 Penalização pela complexidade

$$\lambda \sum_{i=1}^p I(\beta_i \neq 0)$$

conta **quantos coeficientes são diferentes de zero**.

Ou seja, penaliza modelos com **muitas variáveis**.

Ideia central

O parâmetro λ controla o compromisso entre:

- ▶ **qualidade de ajuste**
- ▶ **complexidade do modelo**

Quanto maior λ :

- ▶ menos variáveis são selecionadas
- ▶ o modelo se torna **mais simples**.

Caso sem penalização

Quando $\lambda = 0$ não existe penalização.

Nesse caso, $\hat{\beta}_{L_0}$ coincide com o **estimador de mínimos quadrados**.

Ou seja:

- ▶ **nenhuma variável é descartada**
- ▶ todas as covariáveis permanecem no modelo.

É importante notar que não há penalização para β_0

Busca entre todos os subconjuntos

Para um valor específico de $\lambda = \frac{2\hat{\sigma}^2}{n}$, encontrar a solução para $\hat{\beta}_{L_0}$ equivale a buscar entre todos os modelos da classe

$$G = \{g(x)\}$$

que correspondem a diferentes **subconjuntos de covariáveis**.

Por exemplo:

$$\begin{aligned} G = \{ & g(\mathbf{x}) = \hat{\beta}_0, \\ & g(\mathbf{x}) = \hat{\beta}_0 + \hat{\beta}_1 x_1 \\ & g(\mathbf{x}) = \hat{\beta}_0 + \hat{\beta}_2 x_2 \\ & \vdots \\ & g(\mathbf{x}) = \hat{\beta}_0 + \hat{\beta}_p x_p \\ & g(\mathbf{x}) = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 \\ & g(\mathbf{x}) = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_3 x_3 \\ & \vdots \\ & g(\mathbf{x}) = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \cdots + \hat{\beta}_p x_p \} \end{aligned}$$

Como escolher o melhor modelo?

Uma estratégia é ajustar **cada um dos 2^p modelos** e comparar seus desempenhos. Para isso utilizamos critérios de seleção de modelos, como:

- ▶ **AIC**
- ▶ **BIC**
- ▶ **validação cruzada**

O modelo escolhido é aquele que apresenta o **menor risco estimado**.

Dificuldade computacional

Apesar da ideia ser conceitualmente simples, resolver o problema exatamente pode ser **computacionalmente caro**.


Se existem p covariáveis, então existem 2^p subconjuntos possíveis de variáveis.

Logo, precisaríamos ajustar 2^p **modelos diferentes**.

Por exemplo:

- ▶ $p = 10 \rightarrow 2^{10} = 1024$ modelos
- ▶ $p = 20 \rightarrow 2^{20} = 1.048.576$ modelos

Crescimento do número de modelos



Ideia alternativa

Uma solução é utilizar **heurísticas** que exploram apenas **uma pequena parte do espaço de modelos**, mas ainda assim produzem modelos com **baixo erro preditivo**. Ou seja, buscamos uma **aproximação da solução ótima**, sem precisar avaliar todos os 2^p modelos.

Regressão Stepwise

Uma família de algoritmos que utiliza essa ideia é chamada de **regressão stepwise**.

Esses métodos analisam apenas **um subconjunto dos modelos possíveis**, reduzindo drasticamente o custo computacional.

Ideia do algoritmo

Os métodos stepwise constroem o modelo **sequencialmente**, adicionando ou removendo variáveis.

Em cada etapa, o algoritmo avalia um pequeno conjunto de candidatos e escolhe o modelo que **melhora mais o critério de ajuste**.

Tipos principais

Existem três variantes clássicas:

- ▶ **Forward stepwise**

- ▶ começa com modelo vazio
- ▶ adiciona uma variável por vez

- ▶ **Backward stepwise**

- ▶ começa com todas as variáveis
- ▶ remove uma variável por vez

- ▶ **Stepwise bidirecional**

- ▶ pode adicionar ou remover variáveis em cada etapa

Forward Stepwise Selection

O método **forward stepwise** constrói o modelo **sequencialmente**, adicionando uma variável por vez.

Em cada etapa escolhemos a variável que **mais reduz o risco estimado** (por exemplo, usando **AIC** ou **validação cruzada**).

Passo 1: Escolher a melhor variável isolada

Para cada variável X_j , com $j = 1, \dots, p$, ajustamos o modelo

$$Y = \beta_j X_j + \varepsilon$$

e estimamos o risco $\hat{R}(g_j)$. Escolhemos

$$\hat{j} = \arg \min_j \hat{R}(g_j)$$

e definimos $S = \{\hat{j}\}$.

Passo 2: Adicionar uma nova variável

Para cada variável $j \notin S$, ajustamos

$$Y = \beta_j X_j + \sum_{s \in S} \beta_s X_s + \varepsilon$$

Calculamos novamente o risco estimado $\hat{R}(g_j)$. Seleccionamos

$$\hat{j} = \arg \min_{j \notin S} \hat{R}(g_j)$$

e atualizamos $S \leftarrow S \cup \{\hat{j}\}$.

Passo 3: Repetir

Repetimos o processo:

- ▶ adicionando **uma variável por vez**
- ▶ sempre escolhendo a que **mais reduz o risco estimado**.

O procedimento continua até:

- ▶ todas as variáveis entrarem no modelo, ou
- ▶ não ser mais possível melhorar o ajuste.

Passo 4: Escolher o melhor modelo

Ao final, escolhemos o modelo com **menor risco estimado** ao longo da sequência de modelos gerados.

Vantagem computacional


No **best subset selection** precisaríamos avaliar 2^p modelos.

No **forward stepwise** precisamos ajustar apenas

$$1 + \frac{p(p+1)}{2}$$

modelos.

Isso representa uma **redução enorme no custo computacional**.



Lasso

O **Lasso** (Least Absolute Shrinkage and Selection Operator) foi proposto por Tibshirani (1996).

Seu objetivo é encontrar um estimador da regressão linear que tenha **menor risco preditivo** que o método de mínimos quadrados.

Ideia central

Assim como em outros métodos de regularização, o Lasso busca minimizar:

- ▶ o **erro de ajuste**
- ▶ mais uma **penalização de complexidade**.

A função objetivo é

$$\hat{\beta}_{L_1, \lambda} = \arg \min_{\beta} \sum_{k=1}^n \left(y_k - \beta_0 - \sum_{j=1}^p \beta_j x_{k,j} \right)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

Penalização L_1

No Lasso, a complexidade do modelo é medida pela **norma** L_1 :

$$\sum_{j=1}^p |\beta_j|$$

Essa penalização favorece modelos com **coeficientes pequenos** e frequentemente **iguais a zero**.

Por isso, o Lasso realiza **seleção automática de variáveis**.

Comparação com seleção de subconjuntos

Nos métodos de seleção de variáveis clássicos utilizamos a penalização

$$\sum_{j=1}^p I(\beta_j \neq 0)$$

que corresponde à **norma** L_0 .

No Lasso utilizamos

$$\sum_{j=1}^p |\beta_j|$$

que é a **norma** L_1 .

Essa substituição torna o problema **computacionalmente muito mais fácil de resolver**.

Vantagens do Lasso

Em relação a métodos como **stepwise selection**, o Lasso possui:

- ▶ solução **computacionalmente mais rápida**
- ▶ **melhores propriedades teóricas**
- ▶ capacidade de realizar **seleção automática de variáveis**.

O papel do parâmetro λ no Lasso

Cada valor do **parâmetro de regularização** λ produz um conjunto diferente de coeficientes

$$\hat{\beta}_{L_1, \lambda}$$

Esse parâmetro controla o **grau de penalização aplicado ao modelo**.

Caso 1: $\lambda = 0$

Quando $\lambda = 0$ o problema do Lasso se reduz a

$$\min_{\beta} \sum_{k=1}^n \left(y_k - \beta_0 - \sum_{j=1}^p \beta_j x_{k,j} \right)^2$$

ou seja, ao **estimador de mínimos quadrados**.

Neste caso:

- ▶ não há penalização
- ▶ todos os coeficientes podem ser diferentes de zero

Caso 2: λ grande

Quando λ cresce, o termo de penalização domina:

$$\sum_{k=1}^n \left(y_k - \beta_0 - \sum_{j=1}^p \beta_j x_{k,j} \right)^2 + \lambda \sum_{j=1}^p |\beta_j| \approx \lambda \sum_{j=1}^p |\beta_j|$$

Nesse caso, a solução tende a

$$\hat{\beta}_1 = \dots = \hat{\beta}_p = 0$$

Portanto:

- ▶ o modelo torna-se **extremamente simples**
- ▶ a **variância é muito pequena**
- ▶ mas o **viés é alto**

Como escolher λ ?


Na prática, λ é escolhido por **validação cruzada**.

Procedimento:

1. Ajustar o modelo para vários valores de λ
2. Estimar o risco preditivo $R(g_\lambda)$
3. Selecionar o valor de λ que **minimiza o erro de validação**

Esse processo está ilustrado no **caminho de regularização do Lasso**.

Caminho dos coeficientes no Lasso



Caminho dos coeficientes no Lasso

- ▶ Cada curva representa um **coeficiente do modelo**.
- ▶ Quando λ é pequeno, os coeficientes ficam próximos do ajuste por mínimos quadrados.
- ▶ À medida que λ aumenta, os coeficientes são **encolhidos em direção a zero**.
- ▶ Alguns coeficientes tornam-se **exatamente zero**, realizando **seleção automática de variáveis**.

Regressão Ridge

Uma alternativa ao **Lasso** é a **Regressão Ridge**, introduzida por Hoerl and Kennard (1970). A ideia é buscar um modelo que minimize simultaneamente:

- ▶ o **erro de ajuste do modelo**
- ▶ uma **medida da complexidade do vetor de coeficientes**

Na regressão Ridge isso é feito penalizando a **norma L_2 dos coeficientes**.

Formulação do Problema

O estimador da regressão Ridge é definido como

$$\hat{\beta}_{L_2, \lambda} = \arg \min_{\beta} \sum_{k=1}^n \left(y_k - \beta_0 - \sum_{j=1}^p \beta_j x_{k,j} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

onde

- ▶ y_k é a variável resposta da k -ésima observação
- ▶ $x_{k,j}$ é o valor da j -ésima covariável
- ▶ β_j são os coeficientes do modelo
- ▶ $\lambda \geq 0$ é o **parâmetro de regularização**

Estrutura da Função Objetivo

Erro de ajuste

$$\sum_{k=1}^n \left(y_k - \beta_0 - \sum_{j=1}^p \beta_j x_{k,j} \right)^2$$

Esse termo corresponde ao **erro quadrático residual**.

Penalização Ridge

$$\lambda \sum_{j=1}^d \beta_j^2$$

Esse termo penaliza coeficientes grandes, reduzindo a complexidade do modelo.

Norma L_2

A penalização utilizada corresponde à **norma L_2 do vetor de coeficientes**

$$\|\beta\|_{L_2}^2 = \sum_{j=1}^d \beta_j^2$$

Essa medida representa o **comprimento euclidiano do vetor de parâmetros**.
Penalizar essa quantidade implica restringir a magnitude dos coeficientes.

Papel do Parâmetro λ

O parâmetro λ controla o grau de regularização do modelo.

Valor de λ	Interpretação
$\lambda = 0$	regressão linear clássica
λ pequeno	penalização fraca
λ grande	coeficientes próximos de zero

Assim, λ controla o **trade-off entre ajuste e complexidade do modelo**.

Solução Analítica

Diferentemente do Lasso, a regressão Ridge possui **solução analítica fechada**, dada por

$$\hat{\beta}_{L_2, \lambda} = (X^t X + \lambda I_0)^{-1} X^t y$$

onde

- ▶ X é a matriz de covariáveis
- ▶ y é o vetor de respostas
- ▶ I_0 é uma matriz identidade modificada.

Papel da Matriz Identidade

A matriz I_0 é construída de modo que o **intercepto não seja penalizado**.

$$I_0 = \begin{pmatrix} 0 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ 0 & 0 & 0 & \ddots & 0 \\ 0 & 0 & 0 & \cdots & 1 \end{pmatrix}$$

Ou seja, o coeficiente β_0 não sofre regularização.

Comparação com Regressão Linear

Na regressão linear clássica temos

$$\hat{\beta}_{OLS} = (X^t X)^{-1} X^t y$$

Na regressão Ridge adiciona-se o termo λI_0 . Esse termo torna a matriz

$$X^t X + \lambda I_0$$

mais estável numericamente, especialmente quando existe **alta correlação entre variáveis explicativas**.

Interpretação Geométrica

A regressão Ridge pode ser interpretada como o problema

$$\min \text{Erro} \quad \text{sujeito a} \quad \sum_{j=1}^p \beta_j^2 \leq t$$

Geometricamente:

- ▶ a restrição define uma **esfera no espaço dos coeficientes**
- ▶ a solução ocorre onde essa esfera toca a superfície do erro mínimo.

Comparação entre Ridge e Lasso

Método	Penalização	Efeito
Ridge	L_2	reduz coeficientes
Lasso	L_1	pode zerar coeficientes

Assim:

- ▶ **Ridge** reduz a magnitude dos coeficientes
- ▶ **Lasso** pode realizar **seleção automática de variáveis**

Conclusão

A regressão Ridge é um método fundamental em aprendizado estatístico porque

- ▶ reduz a variância dos estimadores
- ▶ melhora a estabilidade numérica
- ▶ controla a complexidade do modelo
- ▶ funciona bem em presença de **multicolinearidade**.

Por essas razões, métodos de regularização são amplamente utilizados em problemas modernos de **aprendizado de máquina e análise de dados de alta dimensão**.

References

- Hoerl, Arthur E., and Robert W. Kennard. 1970. "Ridge Regression: Biased Estimation for Nonorthogonal Problems." *Technometrics* 12 (1): 55–67.
<https://doi.org/10.1080/00401706.1970.10488634>.
- Tibshirani, Robert. 1996. "Regression Shrinkage and Selection via the Lasso." *Journal of the Royal Statistical Society: Series B (Methodological)* 58 (1): 267–88.