Parte I : Aprendizado Supervisionado

Aprendizado em Alta Dimensão

Onde estamos?

Estudamos diferentes formas de estimar

$$r(\mathbf{x}) = \mathbb{E}(Y \mid \mathbf{X} = \mathbf{x})$$

- KNN e regressão local utilizam **vizinhanças**.
- Splines utilizam **funções de base**.
- Árvores e ensembles utilizam **partições**.
- Redes neurais aprendem **composições de transformações**.

Como esses métodos se comportam quando o número de variáveis aumenta?

Alta dimensionalidade: qual é o problema?

Queremos aprender a relação

$$Y = g(\mathbf{X}) + \varepsilon, \qquad \mathbf{X} \in \mathbb{R}^p, \quad \mathbb{E}(\varepsilon \mid \mathbf{X}) = 0,$$

utilizando n observações e p variáveis de entrada.

Com muitas entradas, precisamos de dados suficientes para distinguir o sinal do ruído. A dificuldade pode aparecer mesmo quando $p < n$.

Pergunta: como a dimensão afeta a redução do erro, quais estruturas simplificam o problema e quais métodos estudados podem aproveitá-las?

A maldição da dimensionalidade

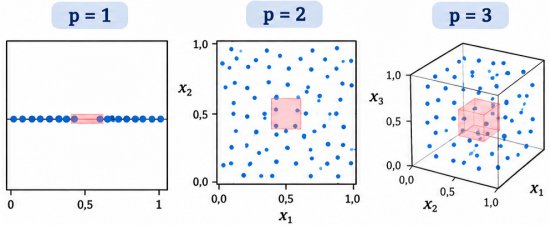
Imagine observações uniformes em $[0,1]^p$. Uma região com comprimento h em cada coordenada ocupa a fração h^p do volume.

Ideia principal

À medida que a dimensão p aumenta, o volume do espaço cresce rapidamente e os dados tornam-se cada vez mais esparsos.

Exemplo

Considere o hipercubo $[0,1]^p$ e uma vizinhança com 10% da extensão em cada variável.
A fração do volume ocupada è $(0,1)^p$.



Dimensão p	Fração do volume $(0,1)^p$
1	0,1
2	0,01
3	0,001
4	0,0001
5	0,00001

Conclusão: vizinhanças que parecem razoáveis em baixas dimensões tornam-se extremamente pequenas em altas dimensões, exigindo muito mais dados para manter a mesma densidade de observações.

A maldição da dimensionalidade

Para manter k observações **em média** nessa região:

$$\boxed{nh^p = k \quad \Longrightarrow \quad n = \frac{k}{h^p}}$$

Por exemplo,

Com $h = 0{,}1$ e $k = 20$	$p = 1$	$p = 3$	$p = 5$
Amostra necessária, em média	200	20.000	2.000.000

A maldição da dimensionalidade

Manter vizinhanças pequenas exige muito mais dados. Isso afeta especialmente KNN e regressão local.

Esta conta ilustra cobertura do espaço sob uniformidade. Não é uma regra geral de tamanho amostral.

Taxa de convergência

A **taxa de convergência** descreve a velocidade com que o risco de estimação diminui à medida que aumentamos o tamanho da amostra n.

Em regressão, podemos medir esse risco pelo **erro quadrático médio de estimação**:

$$R_n = \mathbb{E}\left[(\hat{g}_n(\mathbf{X}) - r(\mathbf{X}))^2\right]$$

em que $\hat{g}_n$ é a função estimada com n observações e r é a verdadeira função de regressão. A esperança considera a amostra de treinamento e uma nova entrada $\mathbf{X}$.

Taxa de convergência

Uma forma comum de descrever a taxa de convergência de um estimador, é dada por

$$\boxed{R_n \approx Cn^{-a}, \qquad C > 0, \quad a > 0,}$$

Assim, por exemplo, quadruplicar a amostra multiplica o termo principal do erro por 4^{-a}.

Taxa de convergência

Expoente	Erro relativo	Redução do erro
$a = 1$	$0{,}25$	**75%**
$a = 1/2$	$0{,}50$	**50%**
$a = 1/6$	$0{,}79$	**21%**

Interpretação: quanto menor o expoente a, mais lentamente o erro diminui com a inclusão de novas observações.

Taxas de convergência e dimensionalidade

Para classes gerais de funções suaves em p dimensões, uma taxa minimax típica do erro quadrático integrado é

$$\boxed{R_n^* \asymp n^{-\frac{2\alpha}{2\alpha+p}}}$$

- α: suavidade da função. Valores maiores impõem maior regularidade.
- R_n^*: melhor risco possível no pior caso da classe considerada.
- $\asymp$: mesma ordem, desconsiderando constantes multiplicativas.

Aumentar p reduz o expoente e torna a aprendizagem mais lenta.

A taxa exige condições sobre a classe de funções, o desenho e o ruído. Mede estimação de g, sem incluir o ruído irredutível de uma nova resposta.

Quanto ganhamos aumentando a amostra?

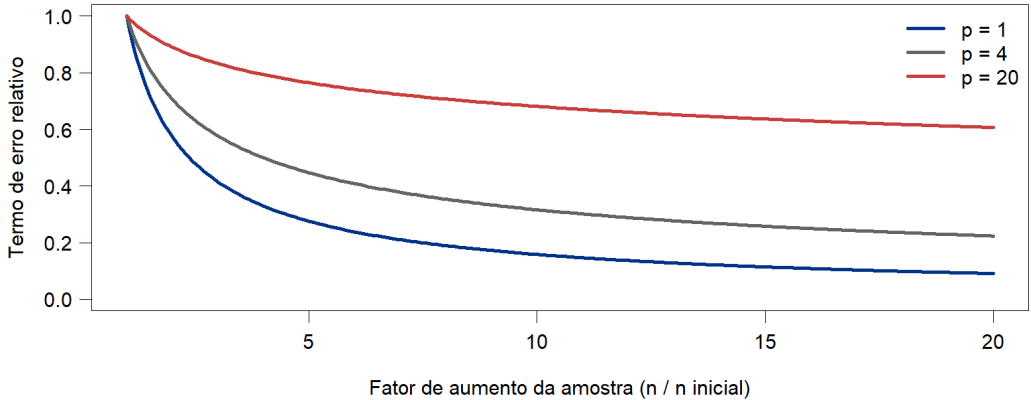
Fixando suavidade $\alpha = 2$, a taxa é $n^{-4/(4+p)}$.

Dimensão p	Taxa	Fator do termo principal com $4n$
1	$n^{-4/5}$	$0{,}33$
4	$n^{-1/2}$	$0{,}50$
10	$n^{-2/7}$	$0{,}67$
20	$n^{-1/6}$	$0{,}79$

Em uma dimensão, o termo cai para cerca de 33% do valor anterior. Em 20 dimensões, permanece em cerca de 79%.

Para reduzir esse termo à metade em $p = 20$, seria necessário multiplicar n por $2^6 = 64$.

A redução do erro fica mais lenta



Todas as curvas começam em 1 para comparar **velocidades de redução**, não níveis absolutos de erro. São curvas teóricas com $\alpha = 2$, sem resultados de ajuste a dados.

Como tornar o problema mais simples?

A taxa anterior considera uma classe ampla de funções em p dimensões.

Podemos explorar hipóteses que reduzam a complexidade relevante:

Hipótese	Ideia	O que procuramos
Esparsidade	Poucas entradas são necessárias à função de predição	Selecionar efeitos relevantes
Redundância	Muitas entradas carregam informação compartilhada	Combinar ou representar informação comum

Ter muitas variáveis observadas não implica que a resposta dependa de todas de forma independente e complexa.

Esparsidade: poucos efeitos ativos

Suponha $p = 1.000$, mas

$$Y = 3X_2 - 2X_{17} + 1{,}5X_{204} + \varepsilon$$

A função de regressão utiliza apenas $s = 3$ entradas: $s \ll p$.

Se soubéssemos quais são, o ajuste seria muito mais simples. Como não sabemos, precisamos encontrá-las entre as 1.000 candidatas.

Lasso pode explorar esparsidade dos coeficientes.

Redundância: muitas medições do mesmo fenômeno

Imagine 100 sensores que medem uma condição térmica comum:

$$X_j = a_j Z + \eta_j, \qquad j = 1, \ldots, 100.$$

Z é a condição compartilhada, a_j é a sensibilidade do sensor e η_j é o ruído específico da medição.

As entradas podem ser fortemente correlacionadas. Se Y depende principalmente de Z, a informação preditiva está associada a uma estrutura simples.

Ridge pode estabilizar o uso conjunto dessas medições.

Métodos mais adequados à alta dimensionalidade

Ridge: estabilidade com muitas entradas

Ridge minimiza o erro de ajuste acrescido de uma penalização quadrática:

$$\sum_{i=1}^{n}(y_i - \beta_0 - \mathbf{x}_i^\top \beta)^2 + \lambda \sum_{j=1}^{p} \beta_j^2$$

Quando considerar: entradas correlacionadas ou sinal distribuído por muitos efeitos pequenos.

Para $\lambda > 0$, o critério produz coeficientes únicos mesmo com $p > n$, no ajuste com intercepto separado.

A penalização estabiliza o ajuste, mas geralmente mantém todos os coeficientes. Uma solução única não garante boa predição: λ precisa ser escolhido por validação.

Lasso: regularização com seleção

Lasso substitui a penalização quadrática pela soma dos valores absolutos:

$$\sum_{i=1}^{n}(y_i - \beta_0 - \mathbf{x}_i^\top \beta)^2 + \lambda \sum_{j=1}^{p} |\beta_j|$$

Quando considerar: poucos efeitos aproximadamente lineares na representação utilizada.

O critério favorece coeficientes exatamente iguais a zero, podendo reduzir o conjunto de entradas utilizadas.

Com entradas fortemente correlacionadas, a escolha de variáveis pode mudar entre amostras. **Selecionar uma variável não prova que ela seja a única portadora do sinal.**

SVM linear: classificação com regularização

A SVM linear utiliza uma função de decisão

$$g(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b$$

com controle da magnitude de $\mathbf{w}$ e penalização das violações da margem.

Quando considerar: classificação com muitas entradas e uma fronteira linear plausível, inclusive em problemas com $p > n$.

Um kernel não linear pode ampliar a flexibilidade, mas distâncias pouco informativas não passam a ser úteis apenas pelo uso do kernel.

RNA: possibilidade de aprender representações

Uma camada oculta calcula

$$\mathbf{a}^{(1)} = \phi(W^{(1)}\mathbf{x} + \mathbf{b}^{(1)}).$$

Ela pode combinar entradas redundantes e representar relações não lineares.

Quando considerar: estrutura não linear que possa ser aprendida com os dados disponíveis, arquitetura adequada e regularização.

- Com H neurônios, a primeira camada já possui $H(p+1)$ parâmetros.
- Weight decay penaliza pesos. Early stopping controla a duração do ajuste pela validação.

Uma RNA não é automaticamente uma boa escolha para $p \gg n$. Com amostra pequena, ridge e lasso são referências importantes para comparação.

Qual método considerar primeiro?

Situação	Método estudado a considerar
Muitas entradas correlacionadas ou muitos efeitos pequenos	Ridge
Poucos efeitos lineares relevantes	Lasso
Classificação com fronteira aproximadamente linear	SVM linear regularizada
Relações não lineares e dados suficientes para aprendê-las	RNA regularizada

A tabela orienta comparações, sem definir um vencedor universal.

Procedimento essencial: estimar padronização, seleção e hiperparâmetros dentro do treinamento/validação. Reservar o teste para a avaliação final.